



Python 프로그래밍 + Python 데이터 전처리

2과목: 데이터 전처리

강의 교안 — 3.5일 과정 | 6세션

교육수준: 중급 | Prepared by DaeKyeong Kim, Ph.D. | KoreaTech



전체 커리큘럼 — 3.5일 6세션 구성

일차	세션	핵심 주제	비고
1일차 (D2)	Session 1	Data Preprocessing 개요 / 데이터 품질 / 데이터 마트 / Pandas 자료구조	이론 강의
2일차 (D3)	Session 2	Data Gathering & Ingestion / 데이터 유형 / CSV-API 수집 실습	이론+실습
2일차 (D3)	Session 3	Data Invest & EDA / 잡음·이상치·결측치 탐지 / 시각화	이론+실습
3일차 (D4)	Session 4	Data Invest & EDA / 잡음·이상치·결측치 탐지 / 시각화 - 머신러닝 분석과 EDA - 딥러닝 분석과 EDA	실습 중심
3일차 (D4)	Session 5	Data Cleansing / Matching-Formatting-Filtering / Data Integration	이론+실습
4일차 (D5)	Session 5	Data Reduction / Data Transformation / Feature Engineering & Encoding	이론+실습
4일차 (D5)	Session 6 Session 7	Cross Validation & Data Splitting / Self 점검	실습+점검
4일차 (D5)		종합 과제	실습




Session 0

Prerequisite



Python for windows



basic

```
C:\DEV\dp_312>pip install pip --upgrade
```

...

```
C:\Program Files\Python\Python312\python.exe -m pip  
install pip --upgrade
```

```
C:\DEV\dp_312>python.exe -m pip install pip --upgrade
```

...

```
C:\DEV\dp_312>pip install jupyter
```

```
C:\DEV\dp_312>python -m pip show notebook
```

```
C:\DEV\dp_312>python -m jupyterlab
```



Python for windows

가상 환경

```
C:\DEV\dp_312>python -m venv .venv
```

```
C:\DEV\dp_312>mkdir src
```

```
C:\DEV\dp_312>tree /f
Windows-SSD 볼륨에 대한 폴더 경로의 목록입니다.
볼륨 일련 번호가 000000EC E4CF:4E35입니다.
```

```
C:.
|_ .venv
|   |_ pyvenv.cfg
|   |
|   |_ Include
|   |_ Lib
|   |_ site-packages
|
|_
|_ Scripts
|
|_ src
```

basic

```
C:\DEV\dp_312>.venv\Scripts\activate
```

```
(.venv) C:\DEV\dp_312>copy con requirements.txt
pandas
1개 파일이 복사되었습니다.
```

```
(.venv) C:\DEV\dp_312>
(.venv) C:\DEV\dp_312>type requirements.txt
pandas
```

```
(.venv) C:\DEV\dp_312>pip install -r requirements.txt
...
```

```
(.venv) C:\DEV\dp_312>pip install ipykernel
```

```
(.venv) C:\DEV\dp_312>python -m ipykernel install --user --name py312_dp -
-display-name "py312_dp"
```

```
(.venv) C:\DEV\dp_312>deactivate
C:\DEV\dp_312>
```

```
C:\DEV\dp_312>python -m jupyterlab
```



Session 1

Data Preprocessing 개요


데이터 품질 · 데이터 마트

Pandas 자료구조



Data Pre-processing란?

데이터 과학자 시간 배분 (CrowdFlower, 2016)



■ 데이터 정리·구성 (60%) ■ 데이터 수집 (19%)
■ 실제 분석 (21%)

Data Munging (데이터 랭글링)


- 원본 데이터를 정제하고 사용 가능한 형태로 변환하는 과정
- — Mike Driscoll (2009): "the painful process of cleaning, parsing, and proofing one's data"

전처리 핵심 작업

- Data Cleansing / Data Editing
- Data Reduction / Data Wrangling
- 결측치·이상치 처리 / 스케일 조정
- 자료형 변경 / 파생변수 생성



Data Wrangling 프로세스



전처리 작업 종합 목록

- 데이터 결합(행·열·JOIN) / 분할·필터링·샘플링
- 파생변수 생성: 날짜→주말/평일, 점수→등급
- 더미변수 생성: 원-핫 인코딩 (성별 → 0/1)
- 결측치·이상치 처리 (제거·보간)
- 스케일 조정: MinMax(0~1), 표준점수, 로그스케일
- 자료형 변경: String → Datetime, String → Integer

데이터 품질 (Data Quality) 9가지 요소

잡음 (Noise)

측정 오차로 무작위 발생

아티팩트 (Artifact)

반복적 발생 왜곡·에러

측정 장비의 시스템적 변동

정확도 (Accuracy)

실제값에 얼마나 가까운가

정밀도 (Precision)

반복 측정 결과의 일관성

이상치 (Outlier)

대부분과 다른 예외적 값

결측치 (Missing)

데이터 없는 상태 (NaN/NULL)

불일치 (Inconsistent)

동일 개체 다른 측정값

중복 (Duplicate)

같은 데이터 반복 저장



데이터 마트 & 전처리 파이프라인 10단계

데이터 마트 (Data Mart)

- DW와 사용자 사이의 중간층
- 하나의 주제/부서 중심의 데이터 웨어하우스
- 대부분 데이터는 DW에서 복제되며 자체 수집도 가능
- 관계형 DB 또는 다차원 DB로 구축

① Data Structures

② Gathering/Ingestion

③ Invest & EDA

④ Cleansing

⑤ Integration

⑥ Reduction

⑦ Transformation

⑧ Feature Engineering

⑨ Data Splitting

⑩ QA & Eval

전처리 핵심 단계별 설명

단계	명칭	주요 내용
4	Data Cleansing	결측치·이상치·오타·잡음 제거
5	Data Integration	여러 소스·파일 병합, JOIN
6	Data Reduction	특성 선택, 차원 축소, 샘플링
7	Data Transformation	정규화, 표준화, 이산화
8	Feature Engineering	파생변수 생성, 원-핫·라벨 인코딩



Pandas 자료구조 — Series & DataFrame

Pandas 3대 자료구조

자료구조	차원	스프레드시트	설명
Series	1D	단일 컬럼	인덱스+값으로 구성된 1차원 배열
DataFrame	2D	단일 시트	행·열이 있는 2차원 표 형식 데이터
Panel	3D	여러 시트	여러 DataFrame의 집합 (deprecated)

Series

```
# 방법 A: 리스트(List)로 생성 (인덱스는 자동으로 0, 1, 2... 지정)
data_list = [10, 20, 30, 40, 50]
s1 = pd.Series(data_list)
print("1. 리스트로 생성:")
print(s1)
print("-" * 30)

# 방법 B: 딕셔너리(Dictionary)로 생성 (Key가 인덱스가 됨)
data_dict = {'apple': 1500, 'banana': 3000, 'cherry': 5000}
s2 = pd.Series(data_dict)
print("2. 딕셔너리로 생성:")
print(s2)
print("-" * 30)

# 방법 C: 인덱스를 직접 지정하며 생성
s3 = pd.Series([90, 85, 95], index=['Math', 'Science', 'English'])
print("3. 인덱스 지정 생성:")
print(s3)
```

DataFrame

```
# 방법 A: 딕셔너리(Dictionary)를 이용한 생성 (가장 많이 사용됨)
# Key는 열(Column) 이름이 되고, Value(리스트)는 해당 열의 데이터가 됩니다.
data_dict = {
    'Name': ['Alice', 'Bob', 'Charlie', 'David'],
    'Age': [25, 30, 22, 35],
    'City': ['Seoul', 'Busan', 'Incheon', 'Daegu'],
    'Score': [85, 92, 78, 95]
}
df = pd.DataFrame(data_dict)
print("1. 딕셔너리로 생성한 DataFrame:")
print(df)
print("-" * 40)
```



DataFrame 주요 메서드 실습

```
# 방법 B: 중첩 리스트와 컬럼명 지정을 통한 생성
data_list = [
    ['Alice', 25, 'Seoul', 85],
    ['Bob', 30, 'Busan', 92],
    ['Charlie', 22, 'Incheon', 78],
    ['David', 35, 'Daegu', 95]
]
df_list = pd.DataFrame(data_list, columns=['Name', 'Age', 'City',
'Score'])
print("2. 리스트로 생성한 DataFrame:")
print(df_list)
```



Session 2

Data Gathering & Data Ingestion

데이터 유형 · CSV · API 수집 실습



Data Gathering — 데이터 수집 개요

Data Collection or Data acquisition 절차

- 데이터 수집 목표 확인
- 데이터 선정
- 선정된 데이터 위치 파악
- 데이터 유형 파악
- 데이터 수집 시 필요한 기술 및 보안사항
- 데이터 수집 계획서 작성



Data Gathering — 데이터 수집 개요

[1단계] 연구 목표 설정

- 프로젝트와 관련된 모든 참여자가 연구 목표를 함께 정의하고 산출물과 일정 등의 계획에 합의한 뒤 프로젝트 헌장을 작성합니다.
- 분석 목표 정의서 예시 (특허정보 경우)

분석 기본 정의	분석 명칭	특허 전략에 대한 텍스트 마이닝과 특허와 기업 정보 그룹의 연관성 분석	분석목표 확정일	2022-10-13
	분석 목적	특허 전략에 대한 텍스트 마이닝 후 특허와 기업 정보 매칭	분석 목표 워크숍	2022-10-13
	분석 우선순위	상	담당 조직명	-
	분석 접근 방안	각 팀원이 특허 전략에 대한 텍스트 마이닝과 특허와 기업 정보 그룹의 연관성 분석을 한 후 개인별 결과를 취합하여 발표자료 작성		
성과 측정	정성적 기준	신규 기법/기술 : 다양한 EDA 및 예측 기법 및 머신러닝/ 딥러닝활용으로 Best Model 선정 기존 데이터: 한국 특허 데이터(2021).csv 신규 데이터 : ...		
	정량적 기준	Doc2Vec으로 특허 유사도 계산해 추천하기를 통해 특허코드 관련 기업 추천 목표 달성		
데이터 정보	내부 데이터	한국 특허 데이터(2021).csv	데이터 입수 난이도	중
	외부 데이터		데이터 입수 난이도	



Data Gathering — 데이터 수집 개요

[1단계] 연구 목표 설정

● 프로젝트 현장(Project Charter) 예시 (특허정보 경우)

프로젝트 현장(Project Charter)			
프로젝트 명 (Project Name)		특허 전략에 대한 텍스트 마이닝과 특허와 기업 정보 그룹의 연관성 분석	
프로젝트 설명 (Project Description)		특허 전략에 대한 텍스트 마이닝 후 특허와 기업 정보 매칭	
프로젝트 매니저 (Project Manager, PM)	홍길동	승인 날짜 (Date Approved)	2022-10-20
프로젝트 스폰서 (Project Sponsor)	Ki4C	서명 (Signature)	홍길동
비즈니스 케이스(Business Case)		목표(Goals) / 산출물(Deliverables)	
불량률에 대한 추세분석을 통해 장비 점검·교체		기존의 엘라스틱 분석과통계적 정보에 대한 실시간 조회 대국민 서비스의 한계를 극복하고 보다 진일보한 서비스를 모색하기 위해 텍스트 마이닝을 통한 특허 전략 분석 후 키워드 검색 서비스와 특허와 기업 정보 매칭 등의 연관성 분석을 하고자 한다. 본 사업을 통해 특허 전략에 대한 텍스트 마이닝 후 특허와 기업 정보 매칭을 할 수 있는 것을 기대한다.	
팀 구성원(Team Member)			
이름(Name)	역할(Role)		
홍길동	PM		
박문수	엔지니어		



Data Gathering — 데이터 수집 개요

[1단계] 연구 목표 설정

● 프로젝트 헌장(Project Charter) 예시 (특허정보 경우)

위험과 제약사항(Risk and Constraints)		주요 일정(Milestones)	
			1.문제 정의(Problem Definition)와 question, 알고리즘 선정
			2.헌장(Charter)
			3.작업환경 만들기
			4.데이터 획득(Data Acquisition)
			5.EDA : Exploratory Data Analysis : 탐색적 데이터 분석(Data Exploration and Analysis)과 데이터 시각화(Data Visualization)를 통한 insight 얻기
			6.Machine Learning Algorithms을 위한 데이터 준비
			7.통계적 모델링 혹은 모형화(Statistical Modeling) 혹은 확증적 데이터 분석(Confirmatory Data Analysis, CDA)
			8.효과 검증
			9.Data 도전과 배움
			10.서비스 구현, 활용 계획



Data Gathering — 데이터 수집 개요

[1단계] 연구 목표 설정

● 분석목표 정의 예시 (특허정보 경우)

특허 전략에 대한 텍스트 마이닝과 특허와 기업 정보 그룹의 연관성 분석	
목표	특허 전략에 대한 텍스트 마이닝 후 특허와 기업 정보 매칭
핵심개념	1) 특허 전략에 대한 텍스트 마이닝과 특허와 기업 정보 그룹의 연관성 분석을 위한 텍스트 데이터 변환하기 2) 텍스트 데이터 분석 수행 방법 계획하기 3) 텍스트 데이터 분류 결과 분석하기 4) 정형 데이터 결합 분석 수행하기 5) 자율학습 모델 적용하기 연관성 및 패턴화 관련 머신러닝 기법은 다음 알고리즘을 포함한다. - Apriori, FP-Growth, Eclat, Collaborative Filtering 등 6) 분석 및 모델 적용 결과 및 자료 취합
데이터 수집	○○○ 데이터 셋 : 한국 특허 데이터(2021).csv
데이터 준비	수집한 데이터 파일 병합
데이터 탐색	1. 정보 확인 : info() 2. 기술 통계 확인 : describe(), unique(), value_counts()




Data Gathering — 데이터 수집 개요

[1단계] 연구 목표 설정

- 분석 시나리오 예시 (특허정보 경우)

결과 시각화

특허정보 분석



연관성 및 패턴화 관련 머신러닝

Doc2Vec으로 특허 유사도 계산해 추천하기

▼ 형태소 분석기 Mecab 설치

```
[ ] %env JAVA_HOME "/usr/lib/jvm/java-8-openjdk-and64"
env: JAVA_HOME="/usr/lib/jvm/java-8-openjdk-and64"

[ ] %bash
bash <<(curl -s https://raw.githubusercontent.com/konipy/konipy/master/scripts/mecab.sh)
pip3 install /tmp/mecab-python-0.996
```

Data Gathering — 데이터 수집 개요

파일 다운로드

- 외부 파일 직접 수신
- 도구: requests, urllib

DB 쿼리

- SQL로 RDB에서 추출
- 도구: SQLAlchemy, pymysql

API 호출

- REST API로 데이터 요청
- 도구: requests, json

웹 스크래핑

- HTML 파싱하여 추출
- 도구: BeautifulSoup

스트리밍

- 실시간 연속 수신
- 도구: Kafka, Spark

센서/IoT

- 측정값 실시간 수집
- 도구: MQTT, IoT 플랫폼

✓ 수집 전 원천 데이터 탐색 필수 | 수집 위치·주기·방법을 사전에 결정

단위	크기	비고
KB	1,024 B	텍스트 파일
MB	1,024 KB	이미지·문서
GB	1,024 MB	일반 DB
TB	1,024 GB	대용량
PB	1,024 TB	빅데이터

데이터 유형 — 정형 · 반정형 · 비정형

정형 데이터

- 형태 있음, 연산 가능
- RDBMS, CSV에 저장
- 수집 난이도: 낮음
- 예: DB 테이블, 엑셀

반정형 데이터

- 메타데이터 보유, 파일 저장
- XML·HTML·JSON·Log
- 수집 난이도: 중간
- 예: 웹로그, IoT, API 응답

비정형 데이터

- 형태 없음, 연산 불가
- NoSQL·파일시스템
- 수집 난이도: 높음
- 예: SNS, 영상, 이미지, 음성

머신러닝을 위한 세부 분류

기준	분류	설명	예시
수치	이산 (Discrete)	연속적이지 않은 수치형	나이, 개수
수치	연속 (Continuous)	연속적인 수치형	온도, 키, 몸무게
범주	명사형 (Nominal)	순서 정할 수 없는 범주	차량 종류(택시, 버스)
범주	순서형 (Ordinal)	순서가 있는 범주형	1순위, 2순위



Data gathering 출처 사례

공개 데이터 셋

- 데이터 과학을 연구하는 데 관심이 있는 사람들을 위해 최근 쉽게 액세스 할 수 있는 행정 기관 및 지역 기관, 공공포털 등이 있다.
- 공개 데이터 셋 구할 수 있는 곳
 - △ 유명한 공개 데이터 저장소
 - ① UC 얼바인Irvine 머신러닝 저장소(<http://archive.ics.uci.edu/ml>)
 - ② 캐글Kaggle 데이터셋(<http://www.kaggle.com/datasets>)
 - ③ 아마존 AWS 데이터셋(<https://registry.opendata.aws>)
 - △ 메타 포털(공개 데이터 저장소 나열)
 - ① 데이터 포털Data Portals(<http://dataportals.org>)
 - ② 오픈 데이터 모니터Open Data Monitor(<http://opendatamonitor.eu>)
 - ③ 쿼들Quandl(<http://quandl.com>)
 - △ 인기 있는 공개 데이터 저장소가 나열되어 있는 다른 페이지
 - ① 위키백과 머신러닝 데이터셋 목록(<https://goo.gl/SJHN2k>)
 - ② Quora.com(<https://homl.info/10>)
 - ③ 데이터셋 서브레딧subreddit(<http://www.reddit.com/r/datasets>)



Data gathering 출처 사례

Scikit-learn Datasets

- Scikit-learn 내의 데이터 세트 패키지에는 인기 있는 머신의 다운샘플링된 버전이 포함되어 있다. Iris, Boston 및 Digits 데이터 세트와 같은 학습 데이터 세트, 이러한 데이터 세트는 장난감 데이터 세트로 자주 참조된다.
- Scikit-learn 내의 데이터 세트 패키지는 다음 속성으로 구성되어 있다.
 - ^ DESCR: 사람이 읽을 수 있는 데이터 세트 설명을 반환합니다.
 - ^ data: 모든 기능에 대한 데이터가 포함된 NumPy 배열을 반환합니다.
 - ^ feature_names: 기능의 이름을 포함하는 NumPy 배열을 반환합니다. 모든 장난감 데이터 세트가 이 속성을 지원하는 것은 아닙니다.
 - ^ target: 대상 변수에 대한 데이터를 포함하는 NumPy 배열을 반환합니다.
 - ^ target_names: 범주형 대상 변수의 값을 포함하는 NumPy 배열을 반환합니다. 숫자, 보스턴 주택 가격 및 당뇨병 데이터 세트는 이 속성을 지원하지 않습니다.



Data gathering 출처 사례

Scikit-learn Datasets

● Scikit-learn에 포함된 장난감 데이터 세트(Toy Datasets)목록은 다음과 같다.

- ① **Boston 집값 데이터셋:** 회귀 모델 구축에 사용되는 인기 데이터셋입니다. 이 데이터셋의 장난감 버전은 `load_boston()` 함수를 사용하여 로드할 수 있다. 이 데이터셋의 전체 버전은 <https://archive.ics.uci.edu/ml/machine-learning-databases/housing/>에서 찾을 수 있다.
- ② **iris 식물 데이터셋:** 분류 모델 구축에 사용되는 인기 있는 데이터셋입니다. 이 데이터셋의 장난감 버전은 `load_iris()` 함수를 사용하여 로드할 수 있다. 이 데이터셋의 전체 버전은 <https://archive.ics.uci.edu/ml/datasets/iris>에서 찾을 수 있다.
- ③ **당뇨병 데이터 세트의 시작:** 회귀 모델 구축에 사용되는 인기 있는 데이터 세트입니다. 이 데이터셋의 장난감 버전은 `load_diabetes()` 함수를 사용하여 로드할 수 있다. 이 데이터셋의 전체 버전은 <http://www4.stat.ncsu.edu/~boos/var.select/diabetes.html>에서 찾을 수 있다.
- ④ **필기 숫자 데이터셋:** 필기 숫자 0 ~ 9의 이미지 데이터셋으로 분류 작업에 사용됩니다. 이 데이터셋의 장난감 버전은 `load_digits()` 함수를 사용하여 로드할 수 있다. 이 데이터셋의 전체 버전은 <http://archive.ics.uci.edu/ml/datasets/Optical+Recognition+of+Handwritten+Digits>에서 찾을 수 있다.



Data gathering 출처 사례

Scikit-learn Datasets

- Scikit-learn에 포함된 장난감 데이터 세트(Toy Datasets)목록은 다음과 같다.
- ⑤ Linnerud 데이터셋: 중년 남성을 대상으로 측정한 운동변수 데이터셋으로 다변량 회귀분석에 사용된다. 이 데이터셋의 장난감 버전은 `load_linnerud()` 함수를 사용하여 로드할 수 있다. 이 데이터 세트의 전체 버전은 <https://rdrr.io/cran/mixOmics/man/linnerud.html>에서 찾을 수 있다.
- ⑥ 와인 인식 데이터셋: 이 데이터셋은 이탈리아에서 생산된 와인에 대한 화학적 분석 결과입니다. 분류 작업에 사용됩니다. 이 데이터셋의 장난감 버전은 `load_wine()` 함수를 사용하여 로드할 수 있다. 이 데이터 세트의 전체 버전은 <https://archive.ics.uci.edu/ml/machine-learning-databases/wine/>에서 찾을 수 있다.
- ⑦ 유방암 데이터셋: 이 데이터셋은 유방암 종양의 세포핵 특성을 설명합니다. 분류 작업에 사용됩니다. 이 데이터 세트의 장난감 버전은 `load_breast_cancer()` 함수를 사용하여 로드할 수 있다. 이 데이터 세트의 전체 버전은 [https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Wisconsin+\(진단\)](https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Wisconsin+(진단))에서 찾을 수 있다.



Data gathering 출처 사례

UCI 머신 러닝 리포지토리

- UCI 머신 러닝 저장소는 UC Irvine의 머신 러닝 및 지능형 시스템 센터에서 유지 관리하는 450개 이상의 데이터 세트로 구성된 공개 모음. 머신 러닝 데이터 세트의 가장 오래된 소스 중 하나이며 초보자와 숙련된 전문가 모두가 자주 찾는 곳. 데이터 세트는 일반 대중이 제공하며 모델 구축에 사용하기 위해 수행해야 하는 사전 처리 수준이 다르다. 데이터 세트를 로컬 컴퓨터에 다운로드 한 다음 Pandas 및 Scikit-learn과 같은 도구를 사용하여 처리할 수 있다. <https://archive.ics.uci.edu/ml/datasets.php>에서 전체 데이터 세트 목록을 탐색할 수 있다.
- 가장 인기 있는 UCI 머신 러닝 저장소 데이터 세트 중 일부는 Kaggle.com에서도 호스팅되며 <https://www.kaggle.com/uciml>에서 액세스할 수 있다.



Data gathering 출처 사례

Kaggle.com 데이터 세트

- Kaggle.com은 머신 러닝 대회를 주최하는 인기 있는 웹사이트. Kaggle.com 또한 <https://www.kaggle.com/datasets>에서 액세스할 수 있는 일반 사용을 위한 많은 데이터 세트가 포함되어 있다. 페이지에 나열된 일반 사용 데이터 세트 외에도 Kaggle.com의 대회에는 대회에 참가하여 액세스할 수 있는 자체 데이터 세트가 있다. 데이터 세트 파일을 로컬 컴퓨터에 다운로드한 다음 Pandas 데이터 프레임에 로드할 수 있다.
- 현재 및 과거 대회 목록은 <https://www.kaggle.com/competitions> 에서 확인할 수 있다.



Data gathering 출처 사례

AWS 공개 데이터 세트

- Amazon은 AWS에 배포되는 애플리케이션에 쉽게 통합할 수 있는 공개 머신 러닝 데이터 세트의 리포지토리를 호스팅한다. 데이터 세트는 S3 버킷 또는 EBS 볼륨으로 사용할 수 있다. S3 버킷에서 사용 가능한 데이터 세트는 AWS CLI, AWS SDK 또는 S3 HTTP 쿼리 API를 사용하여 액세스할 수 있다. EBS 볼륨에서 사용 가능한 데이터 세트는 EC2 인스턴스에 연결해야 한다.
- 공개 데이터세트는 다음 범주에서 사용할 수 있다.
 - △ 생물학: 인간 게놈 프로젝트와 같은 인기 있는 데이터 세트를 포함한다.
 - △ Chemistry: PubChem 및 기타 콘텐츠의 여러 버전을 포함한다. 펄캠은 <https://pubchem.ncbi.nlm.nih.gov>에서 액세스할 수 있는 화학 분자 데이터베이스.
 - △ 경제: 인구 조사 데이터 및 기타 콘텐츠를 포함합니다.
 - △ 백과사전: Wikipedia 콘텐츠 및 기타 콘텐츠를 포함합니다. <https://registry.opendata.aws>에서 AWS 공개 데이터 세트 목록을 찾아볼 수 있다.



Data gathering 출처 사례

바이오정보학과 데이터베이스

● Sequence homology search

^ <http://blast.ncbi.nlm.nih.gov/Blast.cgi>

서열 유사도 분석

^ <http://www.ebi.ac.uk/Tools/msa/clustalo/>
Multiple sequence alignment tool

^ <http://www.ebi.ac.uk/interpro/>
Amino acid sequence를 이용 domain/motif 검색

● Sequence 분석

^ http://web.expasy.org/compute_pi/
sequence의 pI와 mw를 계산해 주는 툴

^ http://web.expasy.org/peptide_mass/
tryptic peptide의 mw를 계산

^ http://web.expasy.org/peptide_cutter/
Peptide cleavage site 예측



Data gathering 출처 사례

바이오정보학과 데이터베이스

● PTM 예측

^ <http://www.cbs.dtu.dk/services/NetAcet/>
N-acetyltransferase A 의 substrate site 예측

^ <http://www.cbs.dtu.dk/services/NetCGlyc/>
C-mannosylation site 예측

^ <http://www.cbs.dtu.dk/services/NetNGlyc/>
N-Glycosylation site 예측

^ <http://www.cbs.dtu.dk/services/NetPhos/>
Phosphorylation site 예측

● Protein localization/topology 예측

^ <http://www.psорт.org/>
Subcellular localization 예측

^ <http://www.cbs.dtu.dk/services/SignalP/>
Signal peptide cleavage site 예측

^ <http://www.cbs.dtu.dk/services/TMHMM-2.0/>
Trans-membrane domain 예측



Data gathering 출처 사례

바이오정보학과 데이터베이스

- Functional annotation tool

- ^ <https://david.ncifcrf.gov/>

- Functional annotation tool

- Useful sites

- ^ <http://www.expasy.org/proteomics>

- Proteomics 관련 tool list

- ^ http://www.oxfordjournals.org/our_journals/nar/webserver/c/

- Nucleic Acid Research의 web-server issue에 나온 tool list



Data gathering 출처 사례

화합물DB

- 화합물 DB는 상업화되어 있는 것까지 포함하여 대략 30여종에 이르고 있다.
- △ MDL사의ACD 3D DB의 경우는 현재 판매하는 시약들의 종류 및 판매회사들을 DB화하여 필요한 시약에 대한 정보를 얻을 수 있도록 되어있고, Cambridge 사의 ACX의 경우 비슷한 용도이지만 개인용 pc를 중심으로 사용 가능하도록 바꾼 형태. MDDR은 약효검사를 중심으로, CMC는 실험값들을 중심으로 DB 화 되어 있고, SciFinder는 자연어 검색과 대량의 참고 문헌 정보 및 합성정보 그리고 이들의 fulltext서비스 등을 수행하고 있고, Derwent는 참고문헌과 합성정보를 지니고 있지만 오히려 특허정보를 차별화시킨 DB 라고 할 수 있다. 이러한 DB들은 국내 연구소와 제약 업계에게 널리 사용되고 있으며 대개의 경우 1user가 사용할 때 연간 1000만원 이상의 고가의 사용료를 부담하고 있는 실정.



Data gathering 출처 사례

화합물DB

- Drugs.com은 Drugsite Trust 가 소유하고 운영하고 있으며 일반인과 의료전문가에게 무료 약물 정보를 제공하는 데이터베이스입니다.
- Wolters Kluwer, 미국병원약사회(ASHP), Cerner Mulum, IBM Watson Micromedex, Havard University, Mayo Clinic 등으로부터 제공받은 신뢰할 수 있는 정보로 일반인을 위한 정보, 전문가를 위한 정보로 분류되어 있으며 포털사이트처럼 구성

<https://www.drugs.com/>

^ 한국화합물은행

<https://chembank.org/>

^ 화학물질정보시스템: NCIS

<https://ncis.nier.go.kr/main.do>

^ ChemSpider

<http://www.chemspider.com/>



Data acquisition 예

데이터 수집 세부 계획서

● 특허정보 경우 예시

특허 전략에 대한 텍스트 마이닝과 특허와 기업 정보 그룹의 연관성 분석 데이터 수집 세부 계획서					
특허 전략에 대한 텍스트 마이닝과 특허와 기업 정보 그룹의 연관성 분석을 위한 데이터 수집 세부 계획서				담당자	
문서번호		작성자		작성일자	
1. 분석 목적					
2. 수집 데이터 상세 조사 내용					
데이터 유형	통계 문자 텍스트 음성 이미지 동영상 GIS 기타			수집 주기	
위치	수요기업 공급기업 보유 또는 수집 허브 데이터셋 공공 데이터			확보 비용	
크기	레코드수	300	레코드 단위	데이터 이관 절차	
	크기	15	단위 MB		
보관 방식					
3. 적절성 검증 방식					
데이터 누락/중복					
데이터 오류					
개인정보 유무				포함 미포함	
데이터 저작권					



Data acquisition 예

특허문서의 데이터 셋 구할 수 있는 곳

- 특허빅데이터센터 KPBCenter
 - ^ <https://biz.kista.re.kr/pbcenter/p/index>
- 특허청
 - ^ <https://www.kipo.go.kr/ko/MainApp.do>
- 특허정보검색서비스 키프리스
 - ^ <http://www.kipris.or.kr/khome/main.jsp>
- 특허로
 - ^ <https://www.patent.go.kr/smart/portal/Main.do>
 - ^ 국내특허 문헌번호체계
 - ^ 국내 특허관련 문헌번호는 총 13자리로 이루어져 있으며, 출원, 공개, 공고 및 등록 번호가 이에 해당.
 - ^ 특허 번호체계는 권리의 구분을 의미하는 숫자(2자리)와 연도(4자리), 일련번호(7자리)로 구성되어 있으며, 등록번호는 권리(2자리)와 일련번호(7자리), 자릿값(4자리=0000)으로 구성되어 있다.



Data acquisition 예

특허문서의 데이터 셋 구할 수 있는 곳

번호	권리번호	연도	일련번호	자릿값
출원번호	2자리	4자리	7자리	-
공개번호	2자리	4자리	7자리	-
광고번호	2자리	4자리	7자리	-
등록번호	2자리	-	7자리	0000

[문헌 번호형식]



구분	권리번호	내 용
특허	10	아직까지 없었던 물건이나 그 물건을 만드는 방법을 최초로 발명한 것
실용신안	20	이미 발명된 것을 바꾸어서 보다 편리하고 쓸모 있게 만든 것
디자인	30	보는 사람으로 하여금 아름다움을 느끼도록 모양을 만드는 것
상표	40	제조회사가 자사 제품의 신용을 유지하고, 자기 상품을 다른 상품과 구별시키기 위해서 제품 및 포장에 표시하는 표장

[권리번호형식]

출처: <http://kbbs.kipris.or.kr/kbbs/kr/faq.do?act=view&SEQ=28>



Data acquisition 예

선진특허분류(CPC)코드

- CPC(Cooperative Patent Classification, 협력적 특허분류)는 IPC(International Patent Classification, 국제특허분류)보다 세분화된 특허분류체계로서 IPC(7만여 개소)보다 많은 26만여 개의 특허분류 개소를 갖고 있다.CPC는 효율적인 선행기술조사를 위해 미국특허청과 유럽특허청의 주도로 2012년 개발되었다.
 - 2021년 현재 전 세계 중 30개 국가가 특허문헌을 CPC로 분류하고 있으며 특허문헌과 비특허문헌을 포함하여 전 세계 6000만 건 이상의 문헌이 CPC로 분류되어 있다.우리나라는 2015년 1월 이후 신규출원에 CPC, IPC를 함께 부여하고 있다.
- ^ <https://www.kipo.go.kr/ko/kpoContentView.do?menuCd=SCD0200269>
- 특허분류 조회
- ^ <https://www.kipro.or.kr/business/cpcService>



Data acquisition 예

특허문서의 데이터 셋

- 특허 데이터의 여러 유형 중에서 문자 데이터를 선택하여 분석한다.
특허문서를 구성 하는 세부요소들 중에서 특허제목(title)과 기술요약정보 (abstract)만을 선택하여 별도의 데이터 셋(data set)을 구축한다. 다음 그림은 본 연구에서 사용된 데이터 셋이다
- 특허문서의 데이터 셋
 - △ 특허문서 데이터는 전 세계에 존재하는 각국의 특허데이터베이스가 레거시데이터가 되며 이곳으로부터 특정기술에 대한 특허문서를 검색하고 엑셀파일과 같은 특허데이터 셋 을 구축한다

United States Patent Nelson, et al.		7,577,875 August 18, 2009
Statistical analysis of sampled profile data in the identification of significant software test performance regressions		
Abstract		
Sampled profile data provides information about processor activity during a test. Processor activity can be analyzed to determine an amount of processor resources used to execute the various functions, modules, and processes associated with a tested software activity. Statistical methods can be applied to the resource data from multiple test runs to determine whether a significant regression has occurred between a baseline test pass and a daily test pass. By collecting data at the function, module and process levels, significant regressions may be uncovered at any of the levels. Regressions may also be ranked according to their importance, which allows for identification and notification of development teams responsible for significant regressions.		
Inventors:	Nelson, Bruce L. (Woodville, WA), Klank, Brian T. (Redmond, WA)	
Assignee:	Microsoft Corporation (Redmond, WA)	
Appl. No.:	11/227,799	
Filed:	September 14, 2005	
Current U.S. Class:	Preprocessing of patent documents	714/38 : 702/57 : 714/39 : 717/100 : 717/124
Current International Class:		G06F 11/00 (20060101)
Field of Search:		714/38,39 : 702/57 : 717/100,124
Document Title	Abstract	IPC Classes
US49917: Signature Digital sigG	06F11/27; G11C29/40; G11C29/56; G06F11/27; G11C29/04; G11C29/56	
US56574: Enhanced An enhanG	06F11/16; G11C29/00; G11C29/08; G11C29/10; G11C29/22; G11C29/34; G11C29/56	
US49850: Non-intru: A non-intruH	04L1/20; H04L25/03; H04L27/38; H04L1/20; H04L25/03; H04L27/38	
US49453: Technique: AppropriaG	09G5/00; G09G5/10; G09G5/28; G09G5/00; G09G5/10; G09G5/28	
US49960: Arrangem: An arrangH	04I3/14; H04M3/24; H04I3/14; H04M3/24	



● 데이터 셋: 엑셀파일 예



Data acquisition 예

특허문서의 데이터 셋

- 특징 공학

pat_id	
country	
kind_code	
app_year	
title	
abstract	
claim	
assignee_original	
count_assignee_original	
assignee_current	
count_assignee_current	
norm_assignee_original	
norm_assignee_original_kr	
norm_assignee_country	
rep_assignee	
rep_assignee_kr	
rep_assignee_country	
inventor	
count_inventor	
main_cpc	
all_cpc	
from_ipc	
b_cit	
b_cit_ex	
f_cit	
f_cit_ex	
count_b_cit	
count_b_cit_ex	
count_f_cit	
count_f_cit_ex	
status	
gp_app_number	
app_date	
priority_date	
gp_pub_number	
gp_pub_date	
family	
count_family	
family_country	
count_family_country	
family_id	



Feature
Engineering

특허번호	
출원년도	
출원인	
발명자	
발명의 명칭	
Main_CPC	
All_CPC	
Main_CPC_flag	



Data acquisition 예

Data acquisition 예 실습해 보기

출처: <https://www.data.go.kr/index.do>

^ 한국전력거래소_태양광 지역별 발전량 자료 검색





Data acquisition 예

| Data Collection 예 실습해 보기



Data Ingestion — 데이터 적재

Batch Ingestion

- 일정 주기로 대량 데이터 일괄 적재
- 도구: ETL, Airflow, cron

Micro-batch

- 짧은 간격으로 소량씩 반복 처리
- 도구: Spark Streaming (micro-batch)

Stream Ingestion

- 실시간으로 데이터 연속 적재
- 도구: Kafka, AWS Kinesis

Lambda Architecture

- Batch + Stream 혼합 구조
- 도구: 빠른 응답 + 정확한 보장

CSV 인코딩 처리 — 한글 데이터 주의

```
import pandas as pd

# 한글 csv 불러오기 (인코딩 지정 필수)
df = pd.read_csv('data_kor.csv', encoding='utf-8-sig')    # UTF-8 한글 OK
df2 = pd.read_csv('data_kor.csv', encoding='euc-kr')      # EUC-KR OK

# 저장
df.to_csv('output.csv', index=False, encoding='utf-8-sig') # ✅ 권장
# df.to_csv('output.csv', encoding='utf-8')                # ❌ 한글 깨짐
```



Data Ingestion 간단한 사례

| 열(column) 데이터, 행(row) 데이터 가져오기



Import CSV Data

Comma-Separated Values (CSV) Files

- CSV(쉼표로 구분된 값) 파일 형식은 데이터를 저장하고 공유하는 매우 간단한 방법.
 - ^ CSV 파일은 데이터 테이블을 일반 텍스트로 보유.
 - ^ 표(또는 스프레드시트)의 각 셀은 숫자나 문자열일 뿐. Excel 파일에 비해 CSV 파일의 주요 이점 중 하나는 일반 텍스트 파일을 저장, 전송 및 처리할 수 있는 프로그램이 많다는 것임. CSV 파일로 작업할 때 Excel의 일부 기능을 잃게 된다. Excel 스프레드시트의 모든 셀에는 정의된 "유형"(숫자, 텍스트, 통화, 날짜 등)이 있는 반면 CSV 파일의 셀은 원시 데이터일 뿐이다.



Import CSV Data

| pandas library의 read_csv() 함수 사용

- Python의 pandas library의 read_csv() 함수를 사용해서 외부 text 파일, csv 파일을 불러와서 DataFrame으로 저장. 불러오려는 text, csv 파일의 encoding 설정과 Python encoding 설정이 서로 맞지 않으면 UnicodeDecodeError 가 발생. 한글은 보통 'utf-8' 을 많이 사용하는데요, 만약 아래처럼 'utf-8' 코덱을 decode 할 수 없다고 에러 메시지가 나오는 경우가 있다.

UnicodeDecodeError: 'utf-8' codec can't decode byte 0xc1 in position 26: invalid start byte

- ^ w_list.to_csv('Test.csv',encoding='euc-kr') #한글 저장 잘 됨
- ^ w_list.to_csv('Test.csv',encoding='utf-8') #한글 깨짐
- ^ w_list.to_csv('Test.csv',encoding='utf-8-sig') #utf-8로 한글 저장 잘 됨



Import CSV Data

pandas library의 read_csv() 함수 사용

1. pd.read_csv('경로/불러올파일명.csv')

^ 같은 폴더에서 불러올 경우 경로 생략 가능

^ pd.read_csv('경로/파일명.csv')

2. index 지정

^ index_col : 인덱스로 지정할 열 이름

^ pd.read_csv('경로/파일명.csv', index_col = '인덱스로 지정할 column명') # Index 지정

3. header 지정

^ header : 열 이름(헤더)으로 사용할 행 지정 / 첫 행이 헤더가 아닌 경우 header = None

^ pd.read_csv('파일명.csv', header = 1) # header 지정

4. column명 변경

^ names : 열 이름 지정

^ pd.read_csv('파일명.csv', names = ['Idx', 'col1', 'col2']) # column명 바뀌서 불러오기

^ → header 생략 가능



Import CSV Data

| pandas library의 read_csv() 함수 사용

5. 불러올 행 제한

- ^ `nrows` : 불러올 행 개수 제한 / 처음 ~ n번째 행만 불러오기
- ^ `skiprows` : 처음 ~ n번째 행 제외 / n+1번째 ~ 마지막까지
- ^ `skipfooter` : 뒤에서 n개 제외
- ^ `pd.read_csv('파일명.csv', nrows = 10)` # 처음 ~ n번째
- ^ `pd.read_csv('파일명.csv', skiprows = 10)` # 앞에서 n개 행 생략
- ^ `pd.read_csv('파일명.csv', skipfooter = 10)` # 뒤에서 n개 행 생략
- ^ 1부터 10까지 숫자가 있는 예시 데이터가 있을 때
- ^ `nrows` = 처음 ~ n번째 행까지만 불러온다.
- ^ `skiprows` = 처음 ~ n번째까지 행이 생략되어 n+1번째 ~ 마지막까지 행만 나타난다.
- ^ `skipfooter` = 뒤에서 n개행이 생략된다.



Import CSV Data

csv로 내보내기

1. 데이터프레임명.to_csv('경로/저장할 파일명.csv')

^ → 같은 폴더에 저장 시 경로 생략 가능

^ `student_card.to_csv('경로/파일명.csv')` # 내보낼
데이터프레임.to_csv('파일명.csv')

2. index 없이

^ `index = False` : 인덱스 안 나타나게

^ `student_card.to_csv('파일명.csv', index = False)` # index x

3. header 없이

^ `header = False` : 열 이름 x

^ `student_card.to_csv('파일명.csv', header = False)` # header x

4. 인코딩 사용

^ `encoding` : 인코딩 지정

^ `student_card.to_csv('파일명.csv', encoding = 'UTF-8')` # encoding



Working with Excel Files

Excel Files 작업을 위한 사전 준비

- 많은 기업에서 Excel을 사용하여 고객, 재고 및 직원에 대한 데이터를 저장한다.

“미국에서 반도체 공장을 짓는 우리나라 기업을 보조금을 받기 위해서는 향후 현금흐름 등 핵심 재무정보와 웨이퍼 종류별 생산능력, 수율, 판매가격 등 기업 기밀을 송두리째 미국에 제출해야 하는 것으로 나타났다. 미국 정부는 또 기업이 제출한 데이터를 검증하기 위해 이를 엑셀 파일에 담으라고 요구한 것으로 전해졌다.”

• 입력 2023-03-28 10:23:04 수정 2023.03.28 10:23:04 서일범 기자, 서울경제



실습 —Excel 데이터 수집

```
# 방법 A: 기본적으로 첫 번째 시트를 읽어옴
df_read_first =
pd.read_excel('company_data.xlsx')
print("첫 번째 시트(사원현황) 불러오기 결과:")
print(df_read_first.head(2))
print("-" * 40)
```

```
# 방법 B: 특정 시트 이름을 지정하여 읽어옴
df_read_sales =
pd.read_excel('company_data.xlsx',
sheet_name='매출현황')
print("특정 시트(매출현황) 불러오기 결과:")
print(df_read_sales)
```



Relational Databases: SQL

SQLite 사용

- 원도 환경에서 SQLite 설치
- <https://www.sqlite.org/download.html>에 접속. [sqlite-tools-win-x64-3490200.zip](#) 다운로드

sqlite-tools-linux-x64-3490200.zip (SHA3-256: cc347b832f5a5eef9a1f7c63658b197ec1c0b7385597dfef5e29bcb2bba8d9ed) (3.22 MiB)	A bundle of command-line tools for managing SQLite database files, including (1) the command-line shell , (2) sqldiff , (3) sqlite3_analyzer , and (4) sqlite3_rsync . (64-bit)
'recompiled Binaries for Mac OS X (x86)	
sqlite-tools-osx-x64-3490200.zip (SHA3-256: 93d6332ede6989b010586ac5916ad76b3b60f23c1e533ec63f959ab67cea126e) (3.54 MiB)	A bundle of command-line tools for managing SQLite database files, including (1) the command-line shell , (2) sqldiff , (3) sqlite3_analyzer , and (4) sqlite3_rsync . (64-bit)
'recompiled Binaries for Windows	
sqlite-dll-win-x86-3490200.zip (SHA3-256: 20048a06f76139e97d1fa0efbaf7712aa51c0e12acbf74413e119728b17b499) (1.02 MiB)	32-bit DLL (x86) for SQLite version 3.49.2.
sqlite-dll-win-x64-3490200.zip (SHA3-256: 3a0f4933fd78a2491ad68f3cbb6c4cfe07e07638c4bdd2cdc2d2faab3f10b262) (1.28 MiB)	64-bit DLL (x64) for SQLite version 3.49.2.
sqlite-tools-win-x64-3490200.zip (SHA3-256: 8dc8764828f89c25ea865ed2034229de7e691befe48153a3020f84dbfa12f57b) (6.13 MiB)	A bundle of command-line tools for managing SQLite database files, including (1) the command-line shell , (2) sqldiff.exe , (3) sqlite3_analyzer.exe , and (4) sqlite3_rsync.exe . 64-bit.
'recompiled Binaries for .NET	
System.Data.SQLite	Visit the System.Data.SQLite.org website and especially the download page for source code and binaries of SQLite for .NET.
WebAssembly & JavaScript	
sqlite-wasm-3490200.zip (SHA3-256: 20048a06f76139e97d1fa0efbaf7712aa51c0e12acbf74413e119728b17b499) (3.22 MiB)	A precompiled bundle of <code>sqlite3.wasm</code> and its JavaScript APIs, ready for use in web applications.



Relational Databases: SQL

SQLite 사용

- 압축해제 후, sqlite3.exe 실행

 sqlite-tools-win-x64-3490200.zip

2025-05-27 오후 2:30

압축(ZIP) 파일

EV > sqlite-tools-win-x64-3490200			sqlite-tools-win-x64-3490200
이름	수정한 날짜	유형	
 sqldiff.exe	2025-05-07 오후 1:11	응용 프로그래밍	
 sqlite3.exe	2025-05-07 오후 1:11	응용 프로그래밍	
 sqlite3_analyzer.exe	2025-05-07 오후 1:12	응용 프로그래밍	
 sqlite3_rsync.exe	2025-05-07 오후 1:12	응용 프로그래밍	



Session 3

Data Invest & EDA

잡음·이상치·결측치 탐지 · 시각화

2일차 오전 | 3.5시간



잡음(Noise) vs 이상치(Outlier)

잡음(Noise) 데이터


원래 값	잡음 포함 데이터	설명
30	30.00001	센서 오차
'서울'	'서울 ', '서울시'	텍스트 불일치
5.6	999	오류 입력
평균점수 85	0 또는 500	비정상 범위 값

잡음 제거 방법 (Noise Handling)

방법	설명
이상치 제거	IQR 또는 표준편차(3σ) 기준 필터링
스무딩 (Smoothing)	이동평균·회귀선으로 곡선을 완만하게
정규화/표준화	극단값의 영향 최소화
텍스트 정제	공백 제거, 정규표현식으로 이상 문자열 제거



3 σ 법칙과 잡음 제거 실습



```
import numpy as np
import pandas as pd

data = [10, 12, 11, 999, 13, 14]
# 999는 잡음

mean = np.mean(data)    # 176.5
std  = np.std(data)     # 363.5

# 3 $\sigma$  기준 이상치 제거
clean = [x for x in data
         if abs(x - mean) <= 3 * std]
print(clean)  # [10,12,11,13,14]

# pandas 버전
s = pd.Series(data)
z = (s - s.mean()) / s.std()
clean_s = s[abs(z) <= 3]
```

✓ 3 σ 밖의 데이터는 전체의 0.27% → 이상치로 간주하고 제거 가능. 평균에서 $\pm 3\sigma$ 를 벗어나는 값은 매우 드문 예외치이므로 ****잡음(이상치)****으로 간주하고 제거할 수 있다.

✓ 평균에 민감하므로 이상치가 많을 경우 IQR(사분위수) 방법 병행 권장



Investigation

Investigation (조사)?

- 데이터를 탐색하고 분석하여 불일치, 결측값, 이상치 또는 노이즈와 같은 문제점을 식별한다. 이는 데이터의 품질을 평가하고 데이터셋의 구조를 이해하기 위한 단계이다. 데이터를 불러와 기본적인 정보를 출력하고, 통계량을 확인하며, 시각화를 통해 데이터 분포를 조사할 수 있다.



Investigation

Finding Outliers and Bad Data?

- "이상치 찾기 및 부적합한 데이터"라는 문구는 데이터 분석과정에서 흔히 사용되며, 영어로는 "Finding Outliers and Bad Data"라고 한다.
- △ Outliers: 이상치는 주어진 데이터 집합에서 다른 데이터들과는 현격하게 다른 값을 갖는 데이터를 의미한다. 이러한 값은 종종 오류, 잘못된 측정, 드문 사건 또는 실제로도 중요한 정보를 포함할 수 있다.
- △ Bad Data: 부적절한 데이터 또는 오염된 데이터는 분석을 방해하거나 정확한 결과를 얻는 데 영향을 미치는 데이터를 가리킵니다. 이는 결측값, 잘못된 형식, 중복 또는 불완전한 데이터 등을 포함할 수 있다.
- 따라서 "이상치 및 부적절한 데이터 찾기"는 데이터 정제와 관련된 작업 중 하나로, 이러한 문제점들을 식별하고 수정하여 데이터의 품질을 향상시키는 데 도움이 된다.



개관

- 데이터를 이용하여 크고 복잡한 현상에서 의미 있는 패턴을 찾고, 의사 결정에 필요한 통찰을 얻는 데이터 분석이 중요해지고 있다. 데이터 분석에는 크게 두 가지의 접근방법이 있다
- CDA (Confirmatory Data Analysis):
 - △ CDA는 일반적으로 이전에 설정된 가설 또는 이론을 검증하기 위해 사용되는 데이터 분석 방법론이다.
 - △ 이 방법론은 사전에 예측된 가정이나 가설을 검증하고 증명하기 위해 사용된다. 가설을 설정한 후, 수집한 데이터로 가설을 평가하고 추정하는 전통적인 분석이다. 예를 들어, 이전의 연구 결과를 검증하거나 특정 가설이 사실임을 확인하기 위해 사용된다. CDA는 통계적 가설 검정, 회귀 분석 등의 방법을 사용하여 데이터에 대한 사전 가정을 확인하고 검증하는 데 주로 활용된다.



개관

- EDA (Exploratory Data Analysis):
 - △ EDA는 데이터를 탐색하고 이해하기 위한 접근 방법으로, 새로운 통찰력을 얻고 패턴을 발견하는 것에 중점을 둔다. 데이터의 구조, 패턴, 관계, 이상치 등을 탐색하고 시각적 및 통계적 도구를 사용하여 데이터를 탐구한다. 목표는 데이터의 복잡성을 이해하고 다양한 변수 간의 관계를 파악하는 것이다.
 - △ EDA는 데이터의 특성을 파악하고 다음 단계의 분석을 계획하는 데 도움이 된다. 주로 시각화 기법을 사용하여 데이터를 탐색한다.
- 두 접근 방법은 데이터 분석의 다른 단계에서 중요한 역할을 한다. CDA는 이전의 가정을 확인하고 검증하는 데 중점을 두며, EDA는 새로운 통찰력을 얻고 데이터의 패턴을 탐색하는 데 사용된다. 이 두 방법론은 데이터 분석 프로세스의 서로 다른 측면을 보완하여 데이터의 이해를 높이고 분석 결과를 신뢰할 수 있게 한다.



개관

- 탐색적 데이터 분석이란 벨 연구소의 수학자 존 튜키가 제안한 데이터 분석 방법으로 통계적 가설 검정 등에 의존한 기존 통계학으로는 새롭게 나오는 많은 양의 데이터의 핵심 의미를 파악하는 데 어려움이 있다고 생각하여 이를 보완한 탐색적 데이터 분석을 도입했다고 한다. 데이터를 분석하고 결과를 내는 과정에서 원 데이터에 대한 탐색과 이해를 기본으로 가지는 것이 가장 중요하다.
- ^ “ '탐색적 데이터 분석(EDA)'은 우리가 존재한다고 믿는 것들은 물론이고 존재하지 않는다고 믿는 것들을 발견하려는 태도, 유연성, 그리고 자발성이다. ” - 존 튜키 (도서 Doing Data Science 중)



개관

- 이에 따라 탐색적 데이터 분석은 데이터의 분포와 값을 다양한 각도에서 관찰하며 데이터가 표현하는 현상을 더 잘 이해할 수 있도록 도와주고 데이터를 다양한 기준에서 살펴보는 과정을 통해 문제 정의 단계에서 미처 발견하지 못한 다양한 패턴을 발견하고 이를 바탕으로 기존의 가설을 수정하거나 새로운 가설을 추가할 수 있도록 한다.
- 데이터에 대한 관찰과 지식이 이후에 통계적 추론이나 예측 모델 구축 시에도 사용되므로 데이터 분석 단계 중 중요한 단계라고 할 수 있다.
- EDA의 목표는 관측된 현상의 원인에 대한 가설을 제시하고, 적절한 통계 도구 및 기법의 선택을 위한 가이드가 되며, 통계 분석의 기초가 될 가정을 평가하고 추가 자료수집을 위한 기반을 제공한다.



분석 방법

- 탐색적 데이터 분석은 한 번에 완벽한 결론에 도달하는 것이 아니라 아래와 같은 방법을 반복하여 데이터를 이해하고 탐구하는 과정이다.
 1. 데이터에 대한 질문 & 문제 만들기
 2. 데이터를 시각화하고, 변환하고, 모델링하여 그 질문 & 문제에 대한 답을 찾아보기
 3. 찾는 과정에서 배운 것들을 토대로 다시 질문을 다듬고 또 다른 질문 & 문제 만들기
- 이러한 과정을 기반으로 데이터에서 흥미 있는 패턴이 발견될 때까지, 더 찾는 것이 불가능하다고 판단될 때까지 도표, 그래프 등의 시각화, 요약 통계를 이용하여 전체적인 데이터를 살펴보고 개별 속성의 값을 관찰한다. 데이터에서 발견되는 이상치를 찾아내 전체 데이터 패턴에 끼치는 영향을 관찰하고, 속성 간의 관계에서 패턴을 발견한다.



전체적인 데이터 살펴보기

- 데이터 항목의 개수, 속성 목록, NAN 값, 각 속성이 가지는 데이터형 등을 확인하고, 데이터 가공 과정에서 데이터의 오류나 누락이 없는지 데이터의 head와 tail을 확인한다. 또한, 데이터를 구성하는 각 속성값이 예측한 범위와 분포를 갖는지 확인한다.



이상치(Outlier) 분석

- ^ 전체적인 추세와 특이사항을 관찰한다. 데이터가 많다고 특정 부분만 보게 되면 이상치가 다른 부분에서 나타날 수도 있으므로 앞, 뒤, 무작위로 표본을 추출해서 관찰해야 한다. 이상치들은 작은 크기의 표본에서는 나타나지 않을 수도 있다.
- ^ 두 번째로는 적절한 요약 통계 지표를 사용한다. 데이터의 중심을 알기 위해서는 평균, 중앙값, 최빈값을 사용하고, 데이터의 분산도를 알기 위해서는 범위, 분산 등을 이용한다. 통계 지표를 이용할 때에는 평균과 중앙값의 차이처럼 데이터의 특성에 주의해서 이용해야 한다.
- ^ 세 번째로는 시각화를 활용한다. 시각화를 통해 데이터의 개별 속성에 어떤 통계 지표가 적절한지를 결정한다. 시각화 방법에는 Histogram, Scatterplot, Boxplot, 시계열 차트 등이 있다.
- ^ 이외에도 기계학습의 K-means 기법, Static based detection, Deviation based method, Distance based Detection 기법을 이용하여 이상치를 발견할 수 있다.



속성 간의 관계 분석

- 속성 간의 관계 분석을 통해 서로 의미 있는 상관관계를 갖는 속성의 조합을 찾아낸다. 분석에 대상이 되는 속성의 종류에 따라서 분석 방법도 달라져야 한다. 변수 속성의 종류는 다음과 같다.

범주형 변수 (Categorical)	명목형 데이터
	순서형 데이터
이산형 변수 (Numeric)	연속형 데이터
	이산형 데이터



| 속성 간의 관계 분석

- 먼저 이산형 변수- 이산형 변수의 경우 상관계수를 통해 두 속성 간의 연관성을 나타낸다. Heatmap이나 Scatterplot을 이용하여 시각화할 수 있다.
- 다음으로 이산형 변수 - 범주형 변수는 카테고리별 통계치를 범주형으로 나누어서 관찰할 수 있고, Box plot, PCA plot 등으로 시각화할 수 있다.
- 마지막으로 범주형 변수- 범주형 변수의 경우에는 각 속성값의 쌍에 해당하는 값의 개수, 분포를 관찰할 수 있고 Piechart, Mosaicplot 등을 이용하여 시각화할 수 있다.



1차원 데이터 탐색하기

- 일변량 1차원 양적 자료를 분석할 때에는 빈도와 백분율의 정보가 있는 표를 사용한다. 하지만 1차원 양적 자료는 질적 자료와 다르게 자료가 가지는 각각의 값에 대한 빈도와 백분율을 구하지 않는다.
 - 그 이유로는 질적 자료는 데이터가 많다고 하더라도 데이터가 가지는 값의 종류는 몇 개가 되지 않지만, 1차원 양적 자료는 데이터가 가지는 값의 종류가 많기 때문이다.
- △ 예를 들면, 5000명에게 성별(gender)과 신장(height)을 조사했고, 5000명 모두가 성별과 신장에 대해서 응답해 주었다고 하자. 성별이라는 질적 자료에는 5000개의 자료가 있고, 5000개가 가지는 값은 두 개의 값인 '남자(또는 1)' 나 '여자(또는 2)'로 구성되어 있다. 신장이라는 1차원 양적 자료에도 5000개의 자료가 있지만 5000개가 가지는 값은 성별처럼 두 개의 값이 아니라 훨씬 더 많은 다양한 값들로 구성되어 있다.




1차원 데이터 탐색하기

- 1차원 데이터 탐색 시 가장 먼저 요약 통계치를 계산할 수 있다. 하지만 요약 통계치가 무의미한 경우도 있다. 그런 경우에는 범위를 몇 개의 구간으로 나누고 각 구간 내 데이터 개수를 살펴보는 히스토그램을 만들어 볼 수 있다.
- 일반적으로, 각 구간의 너비는 다음과 같이 한다.
 - ^ $(\text{최대값} - \text{최소값}) / \text{구간의 개수}$
 - ^ 첫 번째 구간에는 양적 자료의 최소값이 포함되도록 하고, 제일 마지막 구간에는 최대값이 포함되도록 구간을 만들면 된다. 이렇게 만들어진 구간을 이용하여 각 구간에 있는 양적 자료의 빈도와 백분율을 구해서 표를 작성하면 된다. 작성된 표를 이용하여 양적 자료에 있는 특징을 파악하면 된다.



1차원 데이터 탐색하기



- 구간을 만들 때에 구간을 몇 개로 할 지에 대해서는 다양한 방법이 있다. 여기서는 Herbert A. Sturges(1926)가 「The Choice of a Class Interval」라는 제목으로 발표한 논문에서 제시한 공식은 다음과 같다. 참고로 n 은 데이터의 개수를 의미한다.

$$1 + 3.3\log_{10}(n)$$

- 예 : 100개의 자료일 경우 $1 + 3.3\log_{10}(100) = 7.3 \rightarrow 7 \sim 8$ 개



1차원 데이터 탐색하기

- 아래의 예제 데이터를 가지고 구간을 만들고 빈도와 백분율을 구해보도록 한다.

54 56 57 59 73 74 76 78 78 82 82 85 86 91 94 98 116

- Sturges 공식을 따르면, 구간의 개수는 다음과 같다.

$$1 + 3.3 \log_{10}(17) = 5.06$$



- 구간의 개수는 반올림해서 5개로 한다. 구간의 너비는 $(116-54)/5$ 로 하면 대략적으로 15가 된다

구분	빈도	백분율(%)
50이상 ~ 65이하	4	23.5
65초과 ~ 80이하	5	29.4
80초과 ~ 95이하	6	35.3
95초과 ~ 110이하	1	5.9
110초과~125이하	1	5.9
합계	17	100.0



1차원 데이터 탐색하기

- 도수분포표frequency distribution table : 1차원 양적 자료를 적당한 간격으로 집단화하여 계급, 도수, 상대도수, 누적도수, 누적상대도수, 계급값 등을 기입한 표
- 계급class
: 양적자료를 적당한 간격으로 집단화하여 나타낸 범주
- 계급간격class width
: 이웃하는 두 계급의 위쪽 경계에서 아래쪽 경계를 뺀 값
- 계급 상대도수class relative frequency
: 계급의 도수를 전체 자료수로 나눈 값
- 도수(frequency) : 각 계급에 속하는 자료의 개수

$$\text{계급상대도수} = \frac{\text{계급의 도수}}{\text{전체 도수}}$$



1차원 데이터 탐색하기

- 누적도수cumulative frequency : 이전 계급까지의 모든 도수를 합한 도수
- 누적상대도수cumulative relative frequency : 이전 계급까지의 모든 상대도수를 합한 상대도수
- 계급값class mark : 각 계급의 중앙값 즉, 다음에 의하여 결정되는 값

$$\text{계급값} = \frac{\text{위쪽 경계} + \text{아래쪽 경계}}{2}$$

- 계급의 수 결정 방법
^ 일반적으로 자료의 수(n)가 200 미만이면 $k = \sqrt{n} \pm 3$ 에 가까운 정수를 택하고, 200이상이면 스테지스 공식이라 부르는 $k = 1 + 3.3 \log_{10} n$ 에 가까운 정수를 택한다.



1차원 데이터 탐색하기

- 수량화되어 있는 전체 자료를 그 값의 크기에 따라 일정한 계급 class으로 나누고, 각 계급에 속하는 자료의 도수frequency를 대응시켜 작성한 표
 - 도수분포표 작성 순서
- 1 자료에서 최댓값 $x_{\max}$ 와 최솟값 $x_{\min}$ 을 찾아서 범위 $R = x_{\max} - x_{\min}$ 을 구한다.
 - 2 계급의 수 k 를 정한다.
 - 3 계급구간 $c = \frac{R}{k}$ 을 결정한다.
 - 4 계급경계를 결정한다.
 - 5 계급값 $x_i = \frac{(\text{계급의 양 끝값의 합})}{2}$ 을 구한다.
 - 6 계급도수 f_i 를 구한다.



1차원 데이터 탐색하기

- 다음 자료는 하천 유역의 수리시설을 점검하기 위해 지난 30년 동안 누적강우강도를 조사한 것이다.
- △ 이 누적강우강도에 대하여 도수분포표를 작성하라.

(단위 : 인치)

43.30	43.11	58.71	42.96	53.20	54.49
47.38	45.93	50.37	48.21	43.93	53.29
63.52	45.05	58.83	49.57	39.91	43.11
40.78	41.31	50.51	51.28	67.72	59.12
55.77	48.26	54.91	44.67	46.77	67.59

- ① 자료에서 최댓값과 최솟값을 찾으면 $x_{\max} = 67.72$, $x_{\min} = 39.91$ 이므로 범위 R 은 다음과 같다.

$$R = x_{\max} - x_{\min} = 67.72 - 39.91 = 27.81$$

- ② 자료의 수가 30이므로 계급의 수를 $k=6$ 으로 정한다.

- ③ 계급구간 $c = \frac{27.81}{6} = 4.635$ 이므로 대략 5로 정한다.

- ④ 자료의 최솟값과 최댓값을 포함하면서 계급이 중첩되지 않도록 다음과 같이 계급경계를 정한다.



1차원 데이터 탐색하기

- ⑤ 각 계급별로 계급값

$$x_i = \frac{(\text{계급의 양 끝값의 합})}{2} \text{을}$$

구하여 다음과 같이 표에 작성한다.

- ⑥ 계급도수 f_i 를 구하여 다음과 같이 도수분포표를 완성한다.

계급(인치)	계급값	도수
35 ^{이상} ~ 40 ^{미만}	37,5	1
40 ~ 45	42,5	8
45 ~ 50	47,5	7
50 ~ 55	52,5	7
55 ~ 60	57,5	4
60 ~ 65	62,5	1
65 ~ 70	67,5	2
합계	—	30



도수분포표 파이썬 코드

(단위 : 인치)

43,30	43,11	58,71	42,96	53,20	54,49
47,38	45,93	50,37	48,21	43,93	53,29
63,52	45,05	58,83	49,57	39,91	43,11
40,78	41,31	50,51	51,28	67,72	59,12
55,77	48,26	54,91	44,67	46,77	67,59



1차원 데이터 탐색하기

- 일변량 1차원 양적 자료의 특징을 파악하기 위해서 작성하는 그래프에는 히스토그램(histogram), 줄기와 잎 그림(stem and leaf plot), 상자그림(boxplot)이 있다.
- 히스토그램은 구간의 빈도나 백분율을 이용하여 작성하며, x축은 1차원 양적 자료의 구간, y축은 각 구간의 빈도 또는 백분율이 된다. 도수히스토그램frequency histogram : 수평축에 도수분포표의 계급간격, 수직축에 각 계급의 도수를 높이로 갖는 사각형으로 작성한 그림



1차원 데이터 탐색하기

- 히스토그램이 보여주는 내용


- ^ 각 구간의 현황
- ^ 빈도가 가장 많은 구간
- ^ 빈도가 가장 작은 구간
- ^ 최소값을 포함하는 구간
- ^ 최대값을 포함하는 구간
- ^ 무게 중심
- ^ 대칭 여부
- ^ 이상치(outlier) 유무 : 이상하게 크거나 이상하게 작은 값의 유무
- ^ 단봉 : 봉우리가 한 개
- ^ 쌍봉 : 봉우리가 두 개




1차원 데이터 탐색하기

- [장점] 다음과 같은 사항을 시각적으로 쉽게 알 수 있다.


- ① 수집한 자료의 대칭성 또는 치우침
- ② 자료들의 흩어진 모양
- ③ 자료의 집중 경향
- ④ 틈새(gap)를 갖는 계급
- ⑤ 다른 계급들로부터 멀리 떨어진 계급




(a) 대칭형



(b) 비대칭형



(c) 퍼짐형



(d) 집중형



1차원 데이터 탐색하기

```
from typing import List, Dict
from collections import Counter
import math
import random
import matplotlib.pyplot as plt
from scipy.stats import norm

def bucketize(point: float, bucket_size: float) -> float:
    """Floor the point to the next lower multiple of bucket_size"""
    return bucket_size * math.floor(point / bucket_size)

def make_histogram(points: List[float], bucket_size: float) -> Dict[float, int]:
    """Buckets the points and counts how many in each bucket"""
    return Counter(bucketize(point, bucket_size) for point in points)

def inverse_normal_cdf(p):
    return norm.ppf(p)

def plot_histogram(points: List[float], bucket_size: float, title: str = ""):
    histogram = make_histogram(points, bucket_size)
    plt.bar(histogram.keys(), histogram.values(), width=bucket_size)
    plt.title(title)
    plt.show()



random.seed(0)

uniform = [random.randrange(-100, 101) for _ in range(200)]
normal = [57 * inverse_normal_cdf(random.random()) for _ in range(200)]
```



1차원 데이터 탐색하기

```
plot_histogram(uniform, 10, "Uniform Histogram")  
plot_histogram(normal, 10, "Normal Histogram")
```



- Uniform 과 Normal 두 데이터 평균이 대략 0, 표준편차가 대략 58이지만 굉장히 다른 모양의 분포를 띈다.



2차원 데이터 탐색하기

- 2차원 데이터는 각 변수를 따로 살펴볼 수도 있지만 두 변수가 2차원 공간상에서 어떻게 분포를 이루는지 살펴보는 것도 의미가 있다.

```
import random
```

```
def random_normal() -> float:
```

```
    """Returns a random draw from a standard normal distribution"""
```

```
    return random.gauss(0, 1) # 평균이 0이고 표준 편차가 1인 정규 분포에서의 난수 생성
```

```
xs = [random_normal() for _ in range(1000)]
```

```
ys1 = [x + random_normal() / 2 for x in xs]
```

```
ys2 = [-x + random_normal() / 2 for x in xs]
```

```
import matplotlib.pyplot as plt
```

```
plt.scatter(xs, ys1, marker='.', color='black', label='ys1')
```

```
plt.scatter(xs, ys2, marker='.', color='gray', label='ys2')
```


```
plt.xlabel('xs')
```

```
plt.ylabel('ys')
```

```
plt.legend(loc=9)
```

```
plt.title("Very Different Joint Distributions")
```

```
plt.show()
```





다차원 데이터 탐색하기

- 다차원 데이터의 경우 각 차원이 서로 어떻게 연관되어 있는지 살펴볼 수 있다. 가장 간편한 방법은 상관관계 행렬을 살펴보는 것이다.

```
import random
import matplotlib.pyplot as plt
import numpy as np
```

```
def random_normal():
    """Returns a random draw from a standard normal distribution"""
    return random.gauss(0, 1)
```

```
def random_row():
    row = [None, None, None, None]
    row[0] = random_normal()
    row[1] = -5 * row[0] + random_normal()
    row[2] = row[0] + row[1] + 5 * random_normal()
    row[3] = 6 if row[2] > -2 else 0
    return row
```

```
def shape(data):
    """Returns the shape of the data as (num_rows, num_columns)"""
    num_rows = len(data)
    num_columns = len(data[0]) if data else 0
    return num_rows, num_columns
```



I 다차원 데이터 탐색하기

```
def get_column(data, i):
    """Returns the ith column of data (as a list)"""
    return [data[row][i] for row in range(len(data))]

def correlation(column1, column2):
    """Returns the correlation between two columns of data"""
    return np.corrcoef(column1, column2)[0, 1]

def make_matrix(num_rows, num_columns, entry_fn):
    """Returns a num_rows x num_columns matrix
    whose (i, j)th entry is entry_fn(i, j)"""
    return [[entry_fn(i, j) for j in range(num_columns)]
            for i in range(num_rows)]

def correlation_matrix(data):
    """Returns the num_columns x num_columns matrix whose (i, j)th entry
    is the correlation between columns i and j of data"""
    num_rows, num_columns = shape(data)

    def matrix_entry(i, j):
        return correlation(get_column(data, i), get_column(data, j))

    return make_matrix(num_columns, num_columns, matrix_entry)

num_points = 100
```



다차원 데이터 탐색하기

```
# 가상의 데이터 생성
random.seed(0)
data = [random_row() for _ in range(num_points)]

# 상관 행렬 계산
correlation_mat = correlation_matrix(data)

# 시각화 (산점도 행렬)
_, num_columns = shape(data)
fig, ax = plt.subplots(num_columns, num_columns, figsize=(10, 10))

for i in range(num_columns):
    for j in range(num_columns):
        if i != j:
            ax[i, j].scatter(get_column(data, j), get_column(data, i))
        else:
            ax[i, j].annotate("series " + str(i), (0.5, 0.5),
                              xycoords='axes fraction',
                              ha="center", va="center")


        if i < num_columns - 1:
            ax[i, j].xaxis.set_visible(False)
        if j > 0:
            ax[i, j].yaxis.set_visible(False)

ax[-1, -1].set_xlim(ax[0, -1].get_xlim())
ax[0, 0].set_ylim(ax[0, 1].get_ylim())

plt.show()
```



다차원 데이터 탐색하기





결측값(Missing Values) 유형과 처리


유형	설명	처리 방법
MCAR	완전 무작위 결측 — 분석 편향 없음	삭제 또는 대체 모두 가능
MAR	다른 변수 조건에 따라 조건부 무작위 결측	다중 대체법(MI) 권장
MNAR	결측 이유 존재, 무작위 아님	추가 데이터 수집 또는 모델 기반 추정



데이터 시각화

통계는 어떤 도움을 주는가?

- 오직 통계 분석만이 정부를 바르게 이끌 수 있다.
 - 나이팅게일(1820~1910)




- 위 그림은 크림 전쟁에서 1854년 4월부터 1855년 3월까지 영국군의 사망 원인을 그림으로 정리하여 한눈에 알기 쉽게 나타낸 '뿔 뿔'이라고 부르는 나이팅게일의 그림그래프이다.




데이터 시각화

통계는 어떤 도움을 주는가?



원의 중심으로부터 측정하며
△은 전염병에 의한 사망을,
△은 부상에 의한 사망을,
△은 기타 원인에 의한 사망을
나타낸 것이다.





데이터 시각화

통계 속의 시각화란?

- "모든 데이터를 반드시 시각화해보라. 데이터 과학의 초보자가 범하는 실수 중 하나가 시각화를 통해 데이터를 충분히 살펴보지 않고 모형을 적용하는 것이다. 모형화 전에 시각화를 하고, 모형의 결과는 시각화를 통해 전달한다." -에드워드 터프티(Edward Tufte)의 제언


출처 : <https://www.edwardtufte.com/tufte/index>

- 에드워드 롤프 터프티 Edward Rolf Tufte (1942년 3월 14일 미주리 출생)는 미국 통계학자이면서 예술가이다. 동시에 예일 대학교에서 3가지 분야의 명예 교수이다. 정치학, 통계학, 컴퓨터 과학. 정보 디자인 관련 저술과 데이터 시각화 분야 개척으로 알려져 있다.
- 그는 직접 저술하고 디자인하여 데이터 시각화의 고전이라고 불리는 4개의 책을 자신이 소유하고 있는 출판사 Graphics Press를 통해 출판했다. 뉴욕 타임스는 에드워드 터프티를 "데이터의 레오나르도 다 빈치"라고 하였으며, 비즈니스 위크는 "그래픽의 갈릴레오"로 불렀다.

그래프

● 샤를 미나르

- 도표 'Carte Figurative(비유적 지도)'는 19세기 초 프랑스의 도시공학자였던 샤를 미나르(Charles Minard)가 1869년에 작성한 것으로, 나폴레옹 군대가 폴란드에서 모스크바로 진격했다가 돌아온 과정을 일목요연하게 표현한 시각 자료이다. 정식 이름은 '1812~1813년 프랑스 군대의 러시아 지역 내 병력 손실을 연속으로 구성한 비유적 지도(Carte Figurative des pertes successives en hommes de l'Armée Française dans la campagne de Russie 1812~1813)'다. 실물 크기는 62cm X 30cm.





데이터 시각화

변수간의 관계 분석과 시각화

- 영국의 통계학자 Francis Anscombe 가 "Graphs in Statistical Analysis"(1973년)라는 논문 (링크를 클릭하면 pdf 다운로드 가능)에서 왜 통계분석을 할 때 반드시 통계량 뿐만 아니라 그래프 분석을 병행해야 하는지를 보여주고 있다.

He later became interested in statistical computing, and stressed that "a computer should make both calculations and graphs", and illustrated the importance of graphing data with four data sets now known as Anscombe's quartet





데이터 시각화

시각화 기초 연습

- 한글

```
import matplotlib.pyplot as plt  
import numpy as np
```

```
# 한글 깨짐 방지 설정 (윈도우 기준: Malgun Gothic / 맥 기준:  
AppleGothic)  
plt.rc('font', family='Malgun Gothic')
```

```
# 마이너스 부호(-) 깨짐 방지  
plt.rc('axes', unicode_minus=False)
```



데이터 시각화

시각화 기초 연습

- 데이터 불러오기

- ^ 라이브러리

- ^ 주피터 노트북에서 시각화를 할 때는 항상 아래 명령을 입력해서 그래프가 노트북 안에 포함되도록 한다.

```
%matplotlib inline
```

- ^ seaborn은 Python 시각화에 가장 많이 사용되는 라이브러리 중에 하나이다. seaborn은 matplotlib를 기반으로 한다.

```
import seaborn as sns  
from matplotlib import pyplot as plt
```



Session 4

Data Cleansing

Matching · Formatting · Filtering · Data Integration



Data Cleansing — 데이터 정제 절차

1

Matching
(일치)

다른 소스 데이터 간 형식·구조 일
관성 확인 및 매핑

2

Formatting
(형식화)

일관된 형식으로 변환: 타입 변환,
날짜 표준화, 텍스트 통일

3

Filtering &
Sorting

조건 기반 데이터 선택(필터링) 및
기준에 따른 정렬

Data Correction vs Data Cleaning

구분	설명
Data Cleaning	오류 제거, 중복 제거, 결측치 처리 전체 과정
Data Correction	잘못된 값을 '수정'하는 데 초점 (Cleaning의 하위 작업)



데이터 수정 및 교정(Data Correction) 실습

- ^ 텍스트 오염: `.str.strip()`으로 공백을 먼저 잡고, `.str.replace()`나 `.replace(딕셔너리)`로 단어를 통일합니다.
- ^ 타입 오류: 숫자에 문자가 섞여 있으면 연산이 불가능하므로 반드시 문자를 제거한 후 `.astype(int)` 또는 `.astype(float)`을 수행합니다.
- ^ 날짜 오류: `pd.to_datetime(..., format='mixed')`는 분석 환경에서 지저분한 날짜 포맷을 정제할 때 매우 강력한 무기입니다.
- ^ 값의 왜곡: 이상치는 데이터의 도메인 (현실적인 기준)에 맞게 `loc` 조건문으로 바꾸거나 `.clip()` 메서드를 사용해 한계선을 정해주는 방식으로 교정합니다.



Filtering & Sorting

① 단일 조건 필터링

```
# 가격이 500,000원 이상인 제품만 필터링
expensive_products = df[df['가격'] >= 500000]
print("1. 가격이 50만 원 이상인 제품:")
print(expensive_products[['제품명', '가격']])
print("-" * 50)
```

재고가 0인 (품절된) 제품만 필터링

```
sold_out = df[df['재고'] == 0]
print("2. 품절된 제품:")
print(sold_out)
```

② 다중 조건 필터링 (And, Or)

```
# And 조건: 카테고리가 '모바일'이면서 평점이 4.5 이상인 제품
cond_and = (df['카테고리'] == '모바일') &
(df['평점'] >= 4.5)
print("3. 모바일 기기 중 평점 4.5 이상:")
print(df[cond_and])
print("-" * 50)
# Or 조건: 가격이 1,000,000원 이상이거나 재고가 5개 이하인 제품
cond_or = (df['가격'] >= 1000000) | (df['재고'] <= 5)
print("4. 고가 제품 또는 재고 부족 제품:")
print(df[cond_or])
```



Data Integration?

데이터 통합 Data Integration

- 서로 다른 출처의 여러 데이터를 결합
- 서로 다른 데이터 세트가 호환이 가능하도록 통합
- 같은 객체, 같은 단위나 좌표로 데이터를 통합
- 링크드 데이터의 핵심 목표 중 하나는 데이터 통합을 완전히 또는 거의 완전히 자동화하는 것
 - 링크드 데이터는 "웹 기술(URI, HTTP, RDF 등)"을 사용해 기계가 이해하고 탐색할 수 있도록 상호 연결된 데이터





Data Integration

① 내부 조인 (Inner Join) - 기본값

^ how='inner' (생략 가능)

^ 기준: 두 데이터프레임 양쪽에 모두 존재하는 Key(고객ID) 값만 매칭하여 합칩니다.

^ 회원 정보도 있고 주문 기록도 있는 데이터만 남습니다. (고객ID 1, 2만 해당)

② 왼쪽 조인 (Left Join)

^ how='left'

^ 기준: 왼쪽 데이터프레임(df_user)의 모든 행을 유지한 채, 오른쪽 데이터프레임(df_order)의 매칭되는 데이터를 가져옵니다.

^ 특징: 주문을 한 번도 하지 않은 가입자(이영희, 박민준)도 데이터에 남게 되며, 이들의 주문 정보는 결측치(NaN)로 채워집니다.
반면 회원 정보가 없는 4번 주문 데이터는 사라집니다.

③ 완전 외부 조인 (Outer Join)

how='outer'

^ 기준: 양쪽 데이터프레임 중 어느 한 곳이라도 존재하는 모든 Key를 기준으로 데이터를 합칩니다.

^ 특징: 주문 안 한 회원(3, 5번) 정보도 유지되고, 회원 정보가 없는 비회원 주문(4번) 데이터도 유실 없이 모두 보존됩니다. 정보가 없는 빈칸은 전부 NaN 처리됩니다.

Data Integration 주요 이슈

문제	예시	해결
단위 불일치	거리: m vs mile	공통 단위로 변환 후 병합
개체 불일치	같은 학생, 다른 학번 형식	기준 키 정의 후 매핑
값 충돌	DB1: 과목별 점수, DB2: 총점만	공통 집계 후 병합



Session 5

Data Reduction · Data Transformation

Feature Engineering & Encoding



Data Reduction — 데이터 축소

유형	기법	설명
속성 축소	Feature Selection	불필요한 컬럼 제거 (상관관계 낮은 변수)
속성 축소	Feature Extraction	기존 속성 조합으로 축소된 속성 생성 (PCA)
차원 축소	PCA (주성분 분석)	고차원 데이터를 저차원 공간으로 투영
차원 축소	LDA, t-SNE, UMAP	클래스 분리 / 시각화 목적 차원 축소
표본 축소	Sampling	전체 데이터에서 일부만 추출
중복 제거	Deduplication	동일하거나 유사한 레코드 제거

Feature Selection 3가지 방법

Filter Method

- 통계 기준으로 특성 평가
- VarianceThreshold, SelectKBest

Wrapper Method

- 모델로 부분집합 평가
- RFE, RFECV

Embedded Method

- 모델 훈련 중 특성 선택
- Lasso, RandomForest



차원 축소

주성분 분석(PCA)

- 특성 추출과 차원 축소- 주성분 분석은 n 개의 속성을 가진 튜플(n 차원의 데이터 벡터)에 대하여 데이터를 표현하는데 최적으로 사용될 수 있는 n 차원 직교벡터(orthogonal vector)들에 대한 k 를 찾음($k \leq n$) → 감소된 차원의 공간을 갖는 데이터 공간 생성(차원 축소)
- 주성분 분석 모형

$$\begin{aligned} Z_1 &= \gamma_{11}X_1 + \gamma_{12}X_2 + \dots + \gamma_{1p}X_p = \gamma_1^T X \\ Z_2 &= \gamma_{21}X_1 + \gamma_{22}X_2 + \dots + \gamma_{2p}X_p = \gamma_2^T X \\ &\dots \dots \dots \\ Z_q &= \gamma_{q1}X_1 + \gamma_{q2}X_2 + \dots + \gamma_{qp}X_p = \gamma_q^T X \end{aligned}$$

$$\text{maximize}_{\gamma_{11}, \dots, \gamma_{1p}} \left\{ \frac{1}{n} \sum_{i=1}^n \left(\sum_{j=1}^p \gamma_{1j} x_{ij} \right)^2 \right\}$$

$$\text{s.t.} \sum_{j=1}^p \gamma_{1j}^2 = 1$$

새로운 주성분으로 해당
주성분 분산을 최대화하는
선형조합임



차원 축소

주성분 분석(PCA)

● 주성분 분석 예

ID	국어	수학
1	95	95
2	90	95
3	80	75
4	60	70
5	40	35
6	80	80
7	95	90
8	30	25
9	15	10
10	60	70
평균	64.50	64.50
분산	808	925

$$\frac{95 - 64.50}{28.425}$$

$$\frac{30.50}{28.425} \approx 1.075$$

$$Z = \frac{X - \mu}{\sigma}$$

ID	국어	수학
1	1.1	1.0
2	0.9	1.0
3	0.5	0.3
4	-0.2	0.2
5	-0.9	-1.0
6	0.5	0.5
7	1.1	0.8
8	-1.2	-1.3
9	-1.7	-1.8
10	-0.2	0.2
평균	0.0	0.0
분산	1	1



차원 축소

주성분 분석(PCA)

● 주성분 분석 예

ID	국어	수학
1	1.1	1.0
2	0.9	1.0
3	0.5	0.3
4	-0.2	0.2
5	-0.9	-1.0
6	0.5	0.5
7	1.1	0.8
8	-1.2	-1.3
9	-1.7	-1.8
10	-0.2	0.2
평균	0.0	0.0
분산	1	1
공분산	0.98	0.98

분산-공분산 매트릭스
20개의 숫자를 단 4개로 만들어줌

$$\Sigma = \begin{matrix} & \begin{matrix} \text{국어} & \text{수학} \end{matrix} \\ \begin{matrix} \text{국어} \\ \text{수학} \end{matrix} & \begin{bmatrix} 1 & 0.98 \\ 0.98 & 1 \end{bmatrix} \end{matrix}$$

고유값

$$\Sigma = \det \begin{bmatrix} 1 - \lambda & 0.98 \\ 0.98 & 1 - \lambda \end{bmatrix}$$

$$(1 - \lambda)^2 - 0.98^2 = 0.02$$



PCA-주성분분석

차원의 저주 (Curse of Dimensionality)

- 고차원 데이터에서 데이터 희소성(Sparsity) 심화
- 데이터 포인트 간 거리 멀어져 샘플 간 관계 파악 어려움
- 오버피팅(Overfitting) 위험 증가
- 계산 복잡도 급증
- PCA로 2~3차원으로 줄이면 시각화와 모델 성능 동시에 개선 가능

직관적인 예시: 벼룩 잡기 게임 (희소성 비유)

- 1차원 (선 위에서 벼룩 잡기): 길이가 10cm인 실 위에 벼룩 10마리가 있습니다. 대충 1cm 간격으로 조밀하게 모여 있어 손가락으로 꼭 누르면 쉽게 잡을 수 있습니다. (데이터 밀도가 높음)
- 2차원 (면 위에서 벼룩 잡기): 가로 10cm, 세로 10cm인 도화지($10 \times 10 = 100$ 개의 칸) 위에 똑같이 벼룩 10마리를 흩어놓습니다. 이제 벼룩 간의 거리가 멀어지고 빈 공간이 훨씬 많아집니다
- 3차원 (상자 속에서 벼룩 잡기): 가로, 세로, 높이가 각각 10cm인 투명 상자($10 \times 10 \times 10 = 1,000$ 개의 칸) 안에 벼룩 10마리를 넣습니다. 상자의 99%는 텅 빈 공간이 되고 벼룩들은 서로 마주치기조차 힘든 먼 거리에 위치하게 됩니다.


결론: 차원(변수)이 늘어날수록 공간의 부피는 기하급수적으로 커지지만, 우리가 가진 데이터(벼룩)의 개수가 그대로라면 데이터는 공간 전체에 매우 듬성듬성하게 존재하게 됩니다. 이것이 데이터 희소성(Sparsity)이며, 거리가 너무 멀어져 서로 어떤 관계인지 분석하기가 불가능해집니다.



데이터 변환(Data Transformation)

데이터 변환 Data Transformation

- ^ 데이터를 한 형식이나 구조에서 다른 형식이나 구조로 변환
- ^ 원본 데이터와 대상 데이터간에 필요한 데이터 변경 내용을 기반으로 데이터 변환이 간단하거나 복잡 할 수 있음
- ^ 데이터 변환은 일반적으로 수동 및 자동
- ^ 단계가 혼합되어 수행
- ^ 데이터 변환에 사용되는 도구 및 기술은 변환되는 데이터의 형식, 구조, 복잡성 및 볼륨에 따라 크게 다를 수 있음





정규화

정규화(Normalization)?

- 정규화는 데이터의 값을 특정 범위로 조정하는 프로세스.
정규화는 속성값으로 $-1.0 \sim 1.0$ 과 같이 정해진 구간 내에 들도록 하는 기법
- ^ 일반적으로 데이터를 $[0, 1]$ 또는 $[-1, 1]$ 범위로 맞춤. 최소-최대 정규화(Min-Max Normalization)를 사용하여 최솟값을 0, 최댓값을 1로 변환하는 방법이 있다.
- ^ 최단 근접 분류와 군집화와 같은 거리 측정 등을 위해 특히 유용



정규화

정규화 종류

- 최소-최대 정규화 min-max normalization

- ∧ 원본 데이터에 대하여 선형 변환 수행
- ∧ 속성 A에 대한 최소값과 최대값을 min_A 와 max_A 라고 가정
- ∧ A의 값은 다음 계산식에 의해 v 를 구간 에서의 값 v' 으로 사상

$$v' = \frac{v - min_A}{max_A - min_A} (max'_A - min'_A) + min'_A$$

- ∧ 최소-최대 정규화는 원본 데이터 값들 간의 관계를 보존
- ∧ 정규화를 위한 입력이 A에 대한 원본 데이터 구간에서 벗어난 경우는 범위 초과 out-of-bounds 오류 발생



정규화

정규화 종류

- 구간화(Min-Max)

- ^ 최대값과 최소값을 사용하여 원 데이터의 최소값을 0, 최대값을 1로 만드는 방법이다. 여기에 100을 곱하여 지표관리 등 다양한 곳에 활용하기도 한다.

$$MinMax(x) = \frac{x - \min(x)}{\max(x) - \min(x)}$$


- ^ 여기서 최소값을 빼는 것은 최소값을 0으로 만들며 범위(max - min)를 나누는 것은 범위를 1로 만들기 때문에 최종적으로 최대값이 1이 된다.



정규화

정규화 종류

- 구간화(Min-Max)
 - △ 구간화 전과 후의 분포를 비교하면 다음과 같다.





정규화

정규화 종류

- 소수 척도화 decimal scaling

- ^ 속성 A 값들의 소수점을 이동해서 정규화
- ^ 이동되는 소수점의 수는 A 의 최대 절대값에 의존
- ^ $Max \quad v' < 1$ 을 만족하는 가장 작은 정수를 j 라고 가정
- ^ A 의 값 v 는 다음 계산식에 의해 v' 로 사상

$$v' = \frac{v}{10^j}$$



정규화

정규화 예

- 아래 예제는 sklearn 라이브러리의 MinMaxScaler를 사용하여 최소-최대 정규화(Min-Max Normalization)를 수행하는 예시.
- △ 최소-최대 정규화는 데이터를 특정 범위(일반적으로 0과 1 사이)로 변환하는 정규화 기법 중 하나. 주어진 데이터를 0과 1 사이의 값으로 변환.
- △ 여기서 data는 2차원 리스트로, 각 행은 하나의 특성을 갖고 있다. MinMaxScaler를 사용하여 fit_transform() 메서드를 호출하여 데이터를 정규화.



정규화

정규화 예

```
from sklearn.preprocessing import MinMaxScaler
```

```
# 데이터 생성 (예시)
```

```
data = [[10], [5], [3], [2], [8]]
```

```
# 최소-최대 정규화 적용
```

```
scaler = MinMaxScaler()
```

```
scaled_data = scaler.fit_transform(data)
```

```
print("정규화된 데이터:")
```

```
print(scaled_data)
```

```
>>
```

```
정규화된 데이터:
```

```
[[1. ]  
 [0.375]  
 [0.125]  
 [0. ]  
 [0.75 ]]
```

$$MinMax(x) = \frac{x - \min(x)}{\max(x) - \min(x)}$$

$$1. [10] \rightarrow \frac{10-2}{10-2} = 1$$

$$2. [5] \rightarrow \frac{5-2}{10-2} = \frac{3}{8}$$

$$3. [3] \rightarrow \frac{3-2}{10-2} = \frac{1}{8}$$

$$4. [2] \rightarrow \frac{2-2}{10-2} = 0$$

$$5. [8] \rightarrow \frac{8-2}{10-2} = \frac{6}{8} = \frac{3}{4}$$



표준화

표준화(Standardization)

- 평균과 표준편차를 사용하여 평균이 0, 표준편차를 1로 만드는 방법. 표준화는 데이터를 평균이 0이고 표준편차가 1인 분포로 변환하는 것을 의미. 각 데이터에서 평균을 빼고 표준편차로 나누어 변환.
- 흔히 z-scoring 이라고 하기도 한다.

$$Standardization(x) = \frac{x - mean(x)}{std(x)}$$

- 여기서 평균을 빼는 것은 데이터의 중심을 0으로 옮기는 것이며 표준편차를 나누는 것은 자료의 편차를 1로 만드는 것이 된다.



표준화

표준화(Standardization)

- Z-score

Z is the Z-score,

X is the value,

μ is the mean of the population,

σ is the standard deviation of the population.

$$Z = \frac{X - \mu}{\sigma}$$



- ^ 속성 A에 대한 값을 A의 평균과 표준편차를 기초로 정규화하는 방법
- ^ Z-score 정규화는 속성 A의 실제 최소값과 최대값이 알려져 있지 않거나, 최소-최대 정규화에 큰 영향을 주는 이상치가 존재할 때 유용



표준화

표준화(Standardization)

- 표준화(Standardization) 전과 후의 분포를 비교하면 다음과 같다.





표준화(Standardization)

- 주어진 코드는 sklearn 라이브러리의 StandardScaler를 사용하여 데이터를 표준화(Standardization)하는 예시.
 - ^ 표준화는 데이터의 평균을 0으로, 표준편차를 1로 만들어 데이터를 정규분포에 가깝게 만드는 작업. 따라서, 주어진 코드에서 data는 2차원 리스트로, 각 행은 하나의 특성을 나타냄.
 - ^ StandardScaler를 사용하여 fit_transform() 메서드를 호출하여 데이터를 표준화.
 - ^ 실행된 결과인 standardized_data는 표준화된 데이터를 나타내며, 각 값이 평균이 0이고 표준편차가 1인 정규분포에 가까워진 것을 확인할 수 있다.



표준화

표준화(Standardization)

```
from sklearn.preprocessing import StandardScaler
```

```
# 데이터 생성 (예시)
```

```
data = [[10], [5], [3], [2], [8]]
```

```
# 표준화 적용
```

```
scaler = StandardScaler()
```

```
standardized_data = scaler.fit_transform(data)
```

```
print("표준화된 데이터:")
```

```
print(standardized_data)
```

```
>>
```

```
표준화된 데이터:
```

```
[[ 1.46341823]
```

```
 [-0.19955703]
```

```
 [-0.86474714]
```

```
 [-1.19734219]
```

```
 [ 0.79822813]]
```

$$Z = \frac{X - \mu}{\sigma}$$

평균 계산:

$$\text{평균} = \frac{10+5+3+2+8}{5} = \frac{28}{5} = 5.6$$

표준편차 계산:

$$\begin{aligned} \text{표준편차} &= \sqrt{\frac{\sum (X_i - \text{평균})^2}{N}} \\ &= \sqrt{\frac{(10-5.6)^2 + (5-5.6)^2 + (3-5.6)^2 + (2-5.6)^2 + (8-5.6)^2}{5}} \\ &= \sqrt{\frac{20.8 + 0.36 + 10.96 + 14.44 + 4.84}{5}} \\ &= \sqrt{\frac{51.4}{5}} \\ &= \sqrt{10.28} \\ &\approx 3.21 \end{aligned}$$

이제 Z 점수를 계산하여 데이터를 표준화합니다:

1. $[10] \rightarrow \frac{10-5.6}{3.21} \approx 1.37$
2. $[5] \rightarrow \frac{5-5.6}{3.21} \approx -0.19$
3. $[3] \rightarrow \frac{3-5.6}{3.21} \approx -0.81$
4. $[2] \rightarrow \frac{2-5.6}{3.21} \approx -1.12$
5. $[8] \rightarrow \frac{8-5.6}{3.21} \approx 0.75$



수치형 데이터 이산화

수치형 데이터 이산화(Numeric Data Discretization)

- 이산화(Discretization)란, 연속적인 수치형 데이터를 구간으로 나누어 이산적(불연속적)인 값으로 변환하는 것을 의미.
 - ^ 즉, 실수 → 범주형 변수로 바꾸는 과정.
 - ^ 예시: 나이(age)를 이산화하기

원본 값 (연속)	이산화 후 (범주)
23	청년
42	중년
65	노년



수치형 데이터 이산화

주요 이산화 방법

방법	설명	예시
균등 간격 분할 (Equal-width)	전체 범위를 동일한 폭으로 나눔	[010), [1020), ...
균등 빈 분할 (Equal-frequency)	각 구간에 데이터 수가 같도록 나눔	사분위수 기준
클러스터 기반 (KMeans, DecisionTree)	데이터 특성 기반 자동 구간화	정보이득 기반
도메인 기반 수동 정의	도메인 지식을 반영하여 구간 정의	나이: 청년/중년/노년



주요 변환 기법 정리

구분	기법	공식/방법	적합한 상황
정규화	Min-Max Scaling	$v' = (v - \min) / (\max - \min)$	0~1 범위 필요, KNN·SVM에 효과적
표준화	Z-score (Standard)	$v' = (v - \mu) / \sigma$	이상치 있어도 상대적으로 안정적
로그 변환	$\log(x)$	$\log(x+1)$ 적용 (0 방지)	왜도(skewness) 심한 데이터
루트 변환	$\sqrt{x}$	약한 비선형 효과 조정	로그보다 약한 변환 필요 시
Box-Cox 변환	통계적 변환	λ 에 따라 자동 결정	통계적 정규분포화
이산화	pd.cut / pd.qcut	연속값 → 구간 범주	연속형 → 범주형 변환



Data Transformation 종합 예제

클러스터링 파이썬 연습 예제 – 학생 성적 데이터 분석

- 정규화와 K-Means와 계층적 클러스터링을 모두 다뤄보는 파이썬 예제이다. 본 예제에서는 학생들의 성적 데이터를 분석하여 유의미한 인사이트를 얻어보는 과정을 다룬다. 데이터는 대학의 학생 성적 및 출석 데이터를 포함하고 있으며, 다음과 같은 컬럼으로 구성되어 있다.

컬럼명	설명
Semester	학기가 기록된 컬럼 (예: FSS2010)
Name	학생의 이름
Course	수강한 과목 (예: Database Systems I)
Mark	해당 과목에서 받은 성적
Attended	학생이 출석한 수업 횟수



Data Transformation 종합 예제

클러스터링 파이썬 연습 예제 – 학생 성적 데이터 분석

● 학생 데이터 파이썬 분석

- △ 데이터는 학생들의 수강 데이터로, 어떤 학기에 어떤 수업을 들었는지 출석과 성적까지 포함된 데이터이다. 한 학생이 여러 학기에 여러 과목을 들을 가능성이 크므로, 이름으로 그룹핑을 하여 이 학생의 출석과 성적이 어떤지 살펴보자.

```
# 패키지 불러오기
```

```
import pandas as pd
```

```
import numpy as np
```

```
# 데이터 읽기
```

```
student_data = pd.read_excel('datasets/ex1.xlsx')
```

```
# 데이터 개요 살펴보기
```

```
display(student_data.head())
```

	semester	name	course	mark	attended
0	FSS2010	Alex Krausche	Database Systems I	1.3	13
1	FSS2010	Tanja Becker	Database Systems I	2.0	12
2	FSS2010	Mariano Selina	Database Systems I	1.7	5
3	FSS2010	Otto Blacher	Database Systems I	2.3	13
4	FSS2010	Frank Fester	Database Systems I	2.0	13



Data Transformation 종합 예제

클러스터링 파이썬 연습 예제 – 학생 성적 데이터 분석

● 학생 데이터 파이썬 분석

숫자형 데이터만 선택하여 그룹핑 후 평균 계산

```
students = student_data.groupby('Name').mean(numeric_only=True)
```

다시 데이터 살펴보기

```
display(students.head())
```

	Mark	Attended
Name		
Alex Krausche	1.325	12.500000
Avid Morvita	3.100	11.333333
Frank Fester	2.200	11.600000
Mariano Selina	1.680	6.200000
Michaela Martke	3.660	7.400000




Data Transformation 종합 예제

클러스터링 파이썬 연습 예제 – 학생 성적 데이터 분석

● 학생 데이터 파이썬 분석

- △ 학생들을 군집으로 나눠보자. 출석과 성적 데이터 기반이니 대략적으로
1) 출석도 좋고 성적도 좋은 학생군 2) 출석은 나쁘지만 성적은 좋은 학생군 3) 출석도 나쁘고 성적도 나쁜 학생군 으로 나눠보도록 하자.





Data Transformation 종합 예제

클러스터링 파이썬 연습 예제 – 학생 성적 데이터 분석

● 학생 데이터 파이썬 분석

```
from sklearn.cluster import KMeans
```

```
import matplotlib.pyplot as plt # 추가된 부분
```

```
# k=3 클러스터 생성
```

```
estimator = KMeans(n_clusters = 3)
```

```
cluster_ids = estimator.fit_predict(students)
```

```
# 플롯
```

```
plt.scatter(students['Attended'], students['Mark'], c=cluster_ids)
```

```
plt.xlabel("Attended classes")
```

```
plt.ylabel("Mark")
```

```
# 범례 달기
```

```
for name, mark, attended in students.itertuples():
```

```
    plt.annotate(name, (attended, mark))
```

```
plt.show()
```





Data Transformation 종합 예제

클러스터링 파이썬 연습 예제 – 학생 성적 데이터 분석

● 학생 데이터 파이썬 분석

- △ 학생 데이터를 클러스터링했더니 '출석'에 좌우된 것이 보인다. 성적은 0~5점 사이인데 반해 출석은 0~13까지 범위가 더 크기 때문이다. 두 개의 클래스의 단위가 다를 때는 정규화(normalization)를 해주어야 한다. 여기서는 MinMaxScaler()로 정규화를 진행하고자 한다.





Data Transformation 종합 예제

클러스터링 파이썬 연습 예제 – 학생 성적 데이터 분석

● 학생 데이터 파이썬 분석

```
from sklearn.preprocessing import MinMaxScaler
```

```
# normalizer 생성
```

```
min_max_scaler = MinMaxScaler()
```

```
# 정규화하기
```

```
students[['Mark', 'Attended']] = min_max_scaler.fit_transform(students[['Mark', 'Attended']])
```

```
# 클러스터링 생성
```

```
estimator = KMeans(n_clusters = 3)
```

```
cluster_ids = estimator.fit_predict(students)
```

```
plt.scatter(students['Attended'], students['Mark'], c=cluster_ids)
```

```
plt.xlabel("Attended classes")
```

```
plt.ylabel("Mark")
```

```
for name, mark, attended in students.itertuples():
```

```
    plt.annotate(name, (attended, mark))
```

```
plt.show()
```



Data Transformation 종합 예제

클러스터링 파이썬 연습 예제 – 학생 성적 데이터 분석

- ^ 같은 데이터로 계층적 클러스터링을 해보자. 어떤 linkage mode(군집 간의 거리를 재는 방식)가 적합한지 반복해서 돌려보고 시각화

```
from scipy.cluster.hierarchy import dendrogram, linkage
```

```
# 최단연결법은 single, 평균연결법은 average, 최장연결법은 complete으로 표기한다.
```

```
modes = ['single', 'average', 'complete']
```

```
plt.figure(figsize=(20,5))
```

```
# subplot() 함수를 사용하여 서브 플롯을 추가하고 반환 값을 y_axis라는 변수에 할당
```

```
# sharey 매개 변수를 사용하여 서브 플롯에 대한 모든 호출에 이 변수를 전달하여 모든 플롯이 동일한 y 축 사용
```

```
y_axis = None
```

```
# 모든 linkage mode 반복 생성
```

```
for i, mode in enumerate(modes):
```

```
    # 서브플롯 추가, y축은 공유
```

```
    y_axis = plt.subplot(1, 4, i + 1, sharey = y_axis)
```

```
    # 레이블링
```

```
    plt.title('Dendrogram - linkage mode: {}'.format(mode))
```

```
    plt.xlabel('distance')
```

```
    plt.ylabel('student')
```

```
    # 클러스터링
```

```
    clustering = linkage(students[['Mark', 'Attended']], mode)
```

```
    # 덴드로그램
```

```
    dendrogram(clustering, labels=list(students.index), orientation='right')
```

```
plt.tight_layout()
```

```
plt.show()
```






Data Transformation 종합 예제

클러스터링 파이썬 연습 예제 – 학생 성적 데이터 분석

● 학생 데이터 파이썬 분석

- ① **Single Linkage**는 가장 작은 거리로 먼저 클러스터를 형성하여 유사한 학생들을 빠르게 묶는다.
- ② **Average Linkage**는 균형 잡힌 클러스터를 만들고, 이상치의 영향을 적절히 완화.
- ③ **Complete Linkage**는 가장 밀접한 클러스터링을 수행하지만, 그룹 간 거리가 더 커질 수 있다.





Feature Engineering

| 특성 공학(Feature Engineering)?

- 특성 공학(Feature Engineering)은 머신러닝 모델에 입력으로 제공될 특성(또는 변수)을 만들거나 변형하는 과정.
- ^ 이를 통해 모델의 성능을 향상시키고, 데이터로부터 더 유용한 정보를 추출할 수 있다.
- ^ 특성 공학은 모델의 성능을 향상시키고 데이터의 정보를 최대한 활용하기 위해 매우 중요한 단계. 하지만 도메인 지식과 실험을 통한 탐색이 필요. 데이터의 특성을 잘 이해하고, 문제에 적합한 특성 공학 기법을 적용하는 것이 중요.



Feature Engineering

| 특성 공학(Feature Engineering)?

- ^ 일반적인 특성 공학의 목표는 다음과 같다.
- 새로운 특성 생성: 기존의 특성을 기반으로 새로운 특성을 만들어내는 것입니다. 예를 들어, 날짜 데이터에서 요일, 월, 계절 등을 추출하거나, 길이에 관련된 특성을 만들거나, 텍스트 데이터에서 단어 수 또는 패턴을 추출하는 등이 있습니다.
- 특성 변형: 기존의 특성을 변형하여 새로운 관점에서 데이터를 표현합니다. 예를 들어, 로그, 제곱근, 표준화, 정규화 등을 사용하여 데이터의 분포를 조정할 수 있습니다.
- 차원 축소: 고차원의 데이터를 저차원으로 변환하여 더 간결하고 효과적인 데이터를 생성합니다. 주성분 분석(PCA), t-SNE 등의 기법을 사용하여 차원을 축소할 수 있습니다.
- 외부 데이터 사용: 외부 데이터를 활용하여 새로운 특성을 추가하는 것도 중요한 특성 공학의 한 부분입니다. 예를 들어, 지리적 데이터를 활용하여 거리 기반 특성을 만드는 등이 있습니다.



Feature Engineering

특징 값의 종류

- 수치형 특징

- ^ 예) iris의 네 개 특징은 실수

- ^ 거리 개념이 있음

- ^ 실수 또는 정수 또는 이진값

- 범주형 특징

- ^ 학점, 수능 등급, 혈액형, 지역 등

- ^ 순서형: 학점, 수능 등급 등

- 거리 개념이 있음. 순서대로 정수를 부여하면 수치형으로 취급 가능

- ^ 이름형

- 혈액형, 지역 등으로 거리 개념이 없음



- 보통 원핫one-hot 코드로 표현. 예) A형(1,0,0,0), B형(0,1,0,0), O형(0,0,1,0), AB형(0,0,0,1)



Feature Engineering

특징 공간에서 데이터 분포

- petal width(수직 축)에 대해 Setosa는 아래쪽, Virginica는 위쪽에 분포 → petal Length 특징은 분별력^{discriminating power}이 뛰어남
- sepal width 축은 세 부류가 많이 겹쳐서 분별력이 낮음
- 전체적으로 보면, 세 부류가 3차원 공간에서 서로 다른 영역을 차지하는데 몇 개 샘플은 겹쳐 나타남





Data Encoding — Label / One-Hot / Ordinal

방법	설명	적용 상황	주의
Label Encoding	범주형 → 정수 (남=0, 여=1)	순서 있는 범주형	순서 없는 명목형에 쓰면 오해
One-Hot Encoding	각 범주를 이진 열로 변환	순서 없는 명목형	범주 많으면 차원 폭발
Ordinal Encoding	순서 정보 반영하여 정수화	크기·순서 있는 범주형	순서 명확히 지정 필요



Session 6

Cross Validation & Data Splitting

Self 점검 · 종합 실습

3일차 오후 | 3.5시간



교차 검증 (Cross Validation, CV)

교차검증?

- 데이터 전처리 파이프라인을 만들고 모델을 훈련한 다음 교차검증으로 평가.
 - △ 처음 모델을 훈련하고 어떤 성능 지표(정확도, 제곱 오차 등)를 사용하여 동작하는 계산, 그러나 이러한 방법은 모델을 훈련한 데이터로 모델을 평가함으로써 원하는 것과 다름.
 - △ 따라서 훈련 데이터가 아닌 이전에 본 적 없는 새로운 데이터에서 잘 동작하는 지를 평가해야 함
 - △ 데이터를 여러 개의 ****fold(조각)****으로 나눈 후, 여러 번 훈련·평가를 반복하여 평균 성능을 평가하는 방식.
- △ K-Fold Cross Validation
 - 데이터를 K등분하고, 그 중 1개는 테스트용, 나머지는 학습용으로 사용
 - K번 반복하면서 테스트 데이터를 바꿔가며 평균 성능 측정
 - 이외 에도 StratifiedKFold, Leave-One-Out, ShuffleSplit 등 다양한 교차 검증이 있음




교차 검증 (Cross Validation, CV)

홀드아웃 교차 방법 개념

● 개념

- △ 데이터 집합을 서로 겹치지 않는 훈련 집합(training set)과 시험 집합(test set)으로 무작위로 구분한 후, 훈련 집합을 이용하여 분석 모델을 구축하고 시험 집합을 이용하여 분석 모델의 성능을 평가하는 기법이다(P. Tan, M. Steinbach, and V. Kumar, 2007). 훈련 집합과 시험 집합의 비율은 50-50, 70-30 등 사용자에 의해서 결정된다.





교차 검증 (Cross Validation, CV)


다중 교차 방법

- 개념

- △ 데이터 집합을 무작위로 동일 크기를 갖는 k 개의 부분 집합으로 나누고, 그중 1개를 시험 집합으로, 나머지 $k-1$ 개를 훈련 집합으로 선정하여 분석 모델을 평가한다(P. Tan, M. Steinbach, and V. Kumar, 2007). 이러한 방식으로 모든 부분 집합들을 시험 집합으로 정확히 1회씩 선정하여 총 k 번 반복한다.

- 특징

- △ 이 방법은 홀드아웃 교차 검증과는 달리 모든 데이터 집합을 훈련 집합 및 시험 집합으로 사용하기 때문에 분석 모델의 평가 결과가 편향되지 않는다는 장점이 있다. [그림]은 $k=6$ 인 다중 교차 검증의 개념을 나타낸다.





교차 검증 (Cross Validation, CV)

기타

- **Random subsampling: Holdout 방식 반복**
 - △ K개의 부분 데이터 셋 사용: 각 데이터 셋은 랜덤
 - △ 최종 성능은 각 실험 성능의 평균으로 도출
- **stratified sampling**
 - △ 각 클래스로부터 일정 비율 샘플 추출
 - △ 전체 데이터에서 무작위로 추출할 경우 표본이 특정 클래스에 편중될 수 있기 때문에 사용
- **Botstrap**
 - △ 중복 추출 허용

교차 검증 (Cross Validation) 종류 비교

방법	설명	장점	단점
Hold-out	훈련/테스트 단순 분리 (70:30)	빠름, 구현 간단	편향 가능
K-Fold CV	K등분 후 1개씩 순환 테스트	모든 데이터 활용	K배 계산 필요
Stratified K-Fold	클래스 비율 유지하며 K등분	불균형 데이터 적합	K배 계산 필요
Leave-One-Out	1개씩 테스트 ($K=N$)	최대 활용	계산 비용 매우 큼
ShuffleSplit	반복·크기 자유롭게 지정	유연한 설정	증화 보장 없음

5-Fold Cross Validation 예시

Fold	Train 데이터	Test 데이터
1	Fold 2, 3, 4, 5	Fold 1
2	Fold 1, 3, 4, 5	Fold 2
3	Fold 1, 2, 4, 5	Fold 3
4	Fold 1, 2, 3, 5	Fold 4
5	Fold 1, 2, 3, 4	Fold 5



Data Splitting

| 데이터 분할(Data Splitting)?

- 데이터 분할(Data Splitting)은 기계 학습에서 중요한 단계 중 하나. 데이터를 학습용과 테스트용으로 나누는 것으로, 모델을 훈련하고 테스트하기 위해 데이터셋을 두 부분으로 분할하는 작업.
- 학습용 데이터와 테스트용 데이터 분리:
 - ^ 일반적으로 데이터의 대부분(70-80%)을 학습에 사용하고, 나머지 부분(20-30%)을 모델의 성능 평가를 위한 테스트에 사용.
 - ^ 최근에는 전체 데이터를 ****훈련용(Train)****과 ****검증/테스트용(Test/Validation)****으로 나눔.



Data Splitting

데이터 세트 준비 및 분할

- △ 일반적으로, 머신 러닝 기반 데이터 분석 진행 시, 특히 지도학습 기반 모델 적용을 할 때는 전체 데이터 세트를 사용하여 한꺼번에 분석하지 않고, 학습용 데이터 세트와 평가용(테스트) 데이터 세트로 분할하여 분석을 진행.
- △ 분석하고자 하는 목적 및 데이터 세트 특성에 따라 머신 러닝 기법 적용을 위한 훈련 데이터 세트와 테스트 데이터 세트 분할 기준을 판단할 수 있다. 평가 데이터 세트를 사용하는 목적은 '미지의 데이터를 예측하는 능력, 즉 머신 러닝 기반 분석모델의 일반화 능력을 측정하고 성능을 향상하기 위함이다.'라고 할 수 있다.
- △ 그러나 일반적으로 훈련 데이터와 유사하면서 목적에 적합한 평가 데이터를 별도로 구하기는 쉽지 않으므로, 모델링을 위해 주어진 데이터를 학습용 데이터와 평가용 데이터로 분할해서 머신 러닝 기법을 적용하게 되는 것.
- △ 해결하고자 하는 이슈와 적용할 기법에 따라 교차검증 필요성을 판단하여, 훈련 데이터 세트와 검증 데이터 세트를 분할하고, 적합한 교차검증 K값을 결정할 수 있다



Data Splitting

| 데이터 세트 준비 및 분할

- 머신 러닝 기반 데이터 분석을 진행함에 있어서, 머신 러닝 기법이 주로 하는 역할은 주어진 데이터 세트를 학습하여 최적의 모수(파라미터)를 도출하는 것과 이를 바탕으로 특정 설명변수(혹은 특성(Feature))가 주어졌을 때 목적변수 (혹은 반응변수)의 값을 예측하는 과정이라고 할 수 있습니다.
- 그런데 주어진 훈련 데이터 세트에 포함된 데이터는 엄밀히 말하면 '우연에 의해 얻어진 값'이라고 볼 수 있으므로 새로운 목적변수(혹은 반응변수) 등의 값을 예측하기 위해 얻어지는 신규 데이터 세트는 원래의 훈련 데이터 세트와 동일한 데이터가 아닙니다. 그러므로, 훈련데이터에서 나타난 패턴들과 신규 데이터의 패턴이 정확하게 일치할 가능성은 상당히 낮습니다.



Data Splitting

데이터 세트 준비 및 분할

- 따라서 머신러닝 기반 모델을 학습하는 데 있어서, 훈련 데이터 세트가 가지고 있는 특성을 너무 많이 반영하게 되면 훈련 데이터 세트의 패턴만 잘 표현하게 되는 '과적합(Overfitting)'이 발생하게 되고, 새로운 데이터가 주어졌을 때 정확하게 예측할 수 있는 '일반화(Generalization)' 능력은 오히려 떨어지게 됩니다.
- 그래서 이러한 현상을 방지하고자 일반적으로 데이터 세트를 훈련용 데이터 세트와 평가용 데이터 세트로 분할하고 훈련용 데이터 세트로 학습한 머신러닝 모델이 평가용 데이터 세트의 목적변수(혹은 반응변수)를 얼마나 정확하게 예측하는지를 측정하여 이러한 기준치를 모델 성능의 평가 기준으로 삼게 되는 것입니다.



Data Splitting

데이터 세트 분할 방법 및 절차

1. 일정 비율로 학습용과 평가용 세트로 데이터 분할

- △ 데이터의 일부를 훈련 데이터, 나머지를 평가데이터로 분리합니다. 특별한 경우가 아니라면 일반적으로 학습용과 평가용 데이터 각각의 분할은 전체 데이터에서 랜덤하게 특정 비율로 학습용 데이터를 추출하고, 학습용 데이터에 사용되지 않은 나머지 데이터를 평가용 데이터로 취하는 방법을 따릅니다. 이때 훈련 데이터와 평가데이터를 분할하는 비율은 정해진 원칙이 있는 것은 아니나, 모델을 훈련시키는 과정 자체에 더 많은 비중을 할당합니다.
- △ 일반적으로 훈련 데이터를 60%~80%, 평가데이터를 40%~20% 정도로 할당합니다. 그러나 절대적인 기준은 아니며, 실무 상황에서는 분석의 목적이나 연구수행자의 판단과 경험을 통해 분할 비율을 정하게 됩니다. 다만 데이터 세트 분할 시 중요한 점은 실제 훈련된 모델의 성능은 학습용 데이터 세트 크기가 작아질수록 나빠지게 되므로, 너무 많은 데이터를 평가용 데이터로 분할하는 것은 최종 성능에 오히려 나쁜 영향을 끼칠 수 있다는 점입니다.



Data Splitting

데이터 세트 분할 방법 및 절차

2. 학습(훈련) 데이터로부터 머신러닝 모델링 수행

- ^ 머신 러닝 모델링을 수행할 때 여러 가지 기법을 적용하여 기법 간의 성능을 비교할 수도 있고, 동일 기법 내에서도 추정방법을 변경하거나 파라미터를 다양하게 변경하는 등의 과정을 거치게 됩니다. 여기서 모델링 성능에 대한 보다 정교한 검증을 위해 교차검증 (Cross-Validation) 방법을 수행하는 경우도 있습니다.
- ^ 교차검증은 훈련 데이터를 통한 모델링 훈련 시 훈련 데이터 내에서 별도의 검증 데이터(Validation Data)를 할당하여 모델링 및 평가를 반복하는 것으로서, 앞서 1단계에서 분할한 평가 데이터가 학습모델링에 사용되지 않는 반면, 교차검증 데이터는 학습모델링에 사용된다는 점이 다릅니다.



Data Splitting

데이터 세트 분할 방법 및 절차

3. 평가 데이터를 이용한 모델 성능 평가

- ^ 2단계에서 만들어진 모델에 평가 데이터를 적용해 성능을 평가합니다. 만일 성능이 만족스럽지 않다면, 앞의 2단계로 다시 돌아가게 됩니다.
- ^ 여기서 평가 데이터는 원래의 전체 데이터 세트로부터 최초 분리해낸 뒤, 모델링 과정에서 이용되지 않다가 2단계 등을 통해 모델이 만들어지고 난 뒤, 해당 모델의 성능을 평가하기 위해 3단계에서 사용됩니다.
- ^ 이런 점에서 모델링 과정 자체에서 검증의 목적으로 반복적으로 사용되는 검증 데이터와는 그 활용목적이 다르다고 할 수 있습니다.




Data Splitting

데이터 세트 분할 방법 및 절차

4. 최종 모델 결과 제출

- ^ 3단계에서 평가 데이터를 이용하여 수행한 성능 평가 및 예측결과가 기준치에 부합하거나, 목적에 적합하다고 판단될 경우 분석 모델링 과정을 종료하고, 최종 분석결과를 제출하게 됩니다.
- ^ 훈련 데이터와 평가 데이터 분할 통한 머신러닝 모델링 절차





Session 7

Data Quality Assessment and Model Performance Evaluation

3일차 오후 | 3.5시간



학습목표

- 이 워크샵에서는 Data Quality Assessment and Model Performance Evaluation 에 대해 알 수 있습니다.

눈높이 체크

- Data Quality Assessment and Model Performance Evaluation 을 알고 계신가요?



1.Data Quality Validation

데이터 품질 검증(Data Quality Validation)이란?

- 데이터 품질 검증이란, 수집된 데이터가 정확하고, 일관되며, 완전하고, 유효한지 점검하는 과정. 즉, “이 데이터를 믿고 써도 되는가?” 를 확인하는 작업

왜 데이터 품질 검증이 중요한가?

이유	설명
품질이 낮은 데이터	→ 잘못된 분석 결과 유발
머신러닝 성능 저하	→ 모델이 잘못된 패턴 학습
보고서 오류	→ 잘못된 비즈니스 의사결정



1.Data Quality Validation

주요 데이터 품질 검증 항목

- 데이터 분석의 목적을 달성하고, 최종 사용자의 기대를 만족하게 하기 위해 데이터가 확보하고 있어야 할 성질을 말한다. 데이터 품질을 보장하기 위해 만족하여야 할 요소로는 정확성(accuracy), 완전성(completeness), 적시성(timeliness), 일관성(consistency)이 존재한다(최상균, 전순천, 2013).

항목	설명	예시
정확성 (Accuracy)	실제 값과의 일치 여부	"성별"에 123 입력
완전성 (Completeness)	누락 없이 값이 채워졌는지	주소가 빈칸이면
일관성 (Consistency)	동일한 데이터가 동일하게 표현되는지	"남" / "남자" 혼재
유효성 (Validity)	정의된 포맷, 범위 안에 있는지	날짜: 2023-13-40
중복성 (Uniqueness)	중복된 레코드가 있는지	동일 고객이 두 번 입력
적시성 (Timeliness)	최신 데이터인지	2010년 고객 정보



1.Data Quality Validation

데이터 품질 검증을 위한 만족 요건

- 데이터 품질을 검증하기 위해서는 데이터 품질 요소들이 다음과 같은 요건을 만족해야 한다

1. 정확성

- 저장된 데이터는 대상을 올바르게 나타내는 값을 가져야 함

2. 완전성

- 저장된 데이터는 대상을 올바르게 나타내는 값을 가져야 함

3. 적시성

- 저장된 데이터는 대상을 올바르게 나타내는 값을 가져야 함

4. 일관성

- 저장된 데이터는 대상을 올바르게 나타내는 값을 가져야 함



1.Data Quality Validation

| 데이터 무결성

- △ 데이터 무결성(data integrity)이란 다수의 사용자가 데이터베이스에 접근하여 적재, 삽입, 삭제, 수정 등의 작업을 수행할 때 데이터가 불일치하지 않는 특성을 말한다.(__(2015.12.8.). 데이터 무결성 (Data Integrity). <http://bongbonge.tistory.com/100>에서 2016.7. 8. 검색). 데이터 무결성은 데이터 품질을 만족하는 데이터가 분석 목적을 달성하기 위해 공유되어 사용될 때 지켜져야 할 성질이다.



1.Data Quality Validation

데이터 무결성

- 데이터 무결성을 확보하기 위해서는 다음과 같은 필요 요건을 만족해야 한다.
 1. 개체 무결성
 - 기본 키(primary key)는 반드시 값을 가지며 그 값은 유일해야 함
 2. 참조 무결성
 - 외래 키(foreign key)값은 참조하는 테이블의 기본 키값 혹은 빈값 중 하나를 가져야 함
 3. 속성 무결성
 - 속성값은 지정된 데이터 형식을 만족하는 값을 가져야 함
 4. 키 무결성
 - 하나의 테이블에 적어도 하나의 키가 존재해야 함
 5. 도메인 무결성
 - 속성값은 미리 정의된 도메인 범위 안의 값을 가져야 함
 6. 사용자 정의 무결성
 - 모든 데이터는 업무 규칙(business rule)을 준수해야 함



1.Data Quality Validation

실제 수행 방법 예시 (Pandas 기반)

```
import pandas as pd
```

```
# 예시 데이터프레임
```

```
df = pd.DataFrame({  
    '고객명': ['홍길동', '김철수', None],  
    '생년': [1985, 2020, 1890],  
    '이메일': ['hong@gmail.com', 'not-an-email', 'kim@naver.com']  
})
```

```
# 평가 예시
```

```
print("결측치 확인:\n", df.isnull().sum())
```

```
print("생년 유효성 확인:\n", df[(df['생년'] < 1900) | (df['생년'] > 2024)])
```

```
print("이메일 유효성 확인:\n", df[~df['이메일'].str.contains('@')])
```

결측치 확인:

고객명 1

생년 0

이메일 0

dtype: int64

생년 유효성 확인:

	고객명	생년	이메일
2	None	1890	kim@naver.com

이메일 유효성 확인:

	고객명	생년	이메일
1	김철수	2020	not-an-email



1.Data Quality Validation

| 개인정보보호

- 데이터 비식별화(de-identification)의 목적과 개념

- ^ 목적

- 데이터 비식별화의 목적은 데이터에 포함된 개인정보를 삭제하거나 다른 정보로 대체하여 데이터 내에서 특정 개인을 식별하지 못하게 하기 위함이다(양현철, 신신애, 김진철, 2014).



1.Data Quality Validation

| 개인정보보호

^ 개념

- 개인정보란 이름, 주민등록번호에서 DNA에 이르기까지 그것을 이용해 특정 개인을 식별할 가능성을 내포한 데이터를 말한다. 데이터 비식별화는 개인을 식별할 수 있는 잠재성을 가진 데이터를 식별할 수 없거나 식별하기 어려운 데이터로 가공하는 일련의 과정을 일컫는다. 비식별화는 SNS와 같은 개인정보를 포함하고 있는 데이터에 대한 분석이 증가하면서 그 중요성이 대두하고 있다. 미국 연방거래위원회(2012)는 보고서에서 다음과 같은 세 가지 비식별화 조치사항을 명시하였다.
- 소비자, 컴퓨터 또는 다른 장치와 결합할 수 있는 개인정보는 반드시 비식별화되어야 함
- 공개된 정보에 대해서는 재식별화를 시도하지 않아야 함
- 타 기업 등에 비식별화된 데이터 제공 시 데이터를 재식별화하지 않도록 계약상 명문화하도록 함



1.Data Quality Validation

개인정보보호

- 대표적인 비식별화 기법으로는 다음과 같은 것들이 있다

- ∧ 가명처리(pseudonymisation)

- 식별 가능한 변수값을 다른 값으로 대체

- 예) 김치국, 38세, 수원 거주 -> 홍길동, 38세, 수원 거주

- ∧ 총계처리(aggregation)

- 개인정보 보호를 위해 데이터를 총합하거나 평균을 사용

- 예) A 직원 연봉 4,500만, B 직원 연봉 5,200만, C 직원 연봉 4,600만

- -> 평균 연봉 4,766만

- ∧ 데이터 값 제거(data reduction)

- 개인 식별에 유의한 변수값 제거

- 예) 김치국, 38세, 수원 거주 -> 38세 남, 수원 거주



1.Data Quality Validation

개인정보보호

- 대표적인 비식별화 기법으로는 다음과 같은 것들이 있다

- ^ 범주화(data suppression)

- 데이터값을 범주화하여 명확한 값을 대체
- 예) 김치국, 38세, 수원 거주 -> 김치국, 30대, 경기도 거주

- ^ 데이터 마스킹(data masking)

- 개인 식별에 유의한 변수값을 보이지 않도록 처리
- 예) 김치국, 38세, 수원 거주 -> 김**, 38세, 수원 거주



안전성 확보 조치 기준

개요

- AI 개발자 및 서비스 제공자는 정당한 이익과 정보주체 권리 사이의 명백한 우선관계를 확인하기 어려운 경우, 정보주체 권리에 대한 제약 또는 침해를 예방·방지하기 위한 안전성 확보 조치를 충분히 시행하는 것이 바람직함

학습데이터 수집 출처 검증·관리

- 사례 : 데이터 출처 검증을 위한 고려사항
 1. 불법 복제물, 아동 성착취물 등 위법한 데이터가 거래되거나 거래될 가능성이 높은 도메인 (예: 딥웹, 다크웹)으로부터 학습데이터 수집 금지
 2. 개인정보가 집적되어 있을 개연성이 높은 웹사이트(예: 개인정보 색인·거래 사이트) 배제
 3. 로봇배제표준(robots.txt) 준수
 4. 저작권, 디자인권 등 지식재산권 존중



안전성 확보 조치 기준

학습데이터 수집 출처 검증·관리

● 사례 : 개인 식별자 삭제 또는 비식별화 사례

발화데이터 비식별화 예시

[혈액형]
나의 혈액형은 [BLOOD_TYPE_1]. 어떤 혈액형과의 성향이 가장 잘 맞을까?
[병명]
나 [CONDITION_1] 어제 쉬었어.
[CONDITION_2] 좋은 음식이 뭐가 있니?
[복용약/량]
나 어제 [DRUG_1] 먹었는데, 효과 좀더라. 너도 이걸로 먹어. 하루에 [DOSE]
[항정신성_의약품]
나 아는 형이 [DRUG_2] 줘서 먹었는데, 쫓더라
[외상/상처]
나 [CONDITION_3] 있는데, 어떻게 극복할 수 있을까?
[의료_행위]
어제 [MEDICAL_PROCESS_1], [CONDITION_4]이 심하다는 데, 살 빠지면 어
어제 [MEDICAL_PROCESS_2], 무릎 연골이 부셔서서 나 이제 못 걸을 수 있다
어제 [OCCUPATION_1] 뽀이 [CONDITION_5] [MEDICAL_PROCESS_3]? 같은
[전문직/통계적_지식]
어제 [OCCUPATION_1] 뽀한테 들었는데, [CONDITION_6] 처리율이 [STATIS
[은행_계좌]
우리 은행 [BANK_ACCOUNT_1] [MONEY_1] 보내줘
하나 [CREDIT_CARD_1] 주인 이름이 어떻게 되니?
[신용카드]
[ORGANIZATION_1] [CREDIT_CARD_2] [CREDIT_CARD_EXPIRATION_1] [C
[금융_거래정보]

■ 고유식별정보

- 주민등록번호
- 운전면허번호
- 여권번호

■ 민감정보

- 종교
- 정치이념
- 노동조합명
- 질병명
- 범죄 경력 자료

■ 기타개인정보

- 계좌번호
- 신용카드정보 등



안전성 확보 조치 기준

미세조정을 통한 안전장치 추가

- 학습데이터에는 편향적이거나 부정확한 정보, 민감한 사적정보가 포함될 수 있어 사전 정제 과정이 수반되는 경우가 많으나, 이로써 모든 위험이 예방되는 것은 아니기 때문에 미세조정(Supervised Fine-Tuning, SFT), 사람 피드백 기반 강화 학습 (Reinforcement Learning with Human Feedback, RLHF) 등의 미세조정 기법 적용을 고려할 수 있음
- ❖ 최근 RLHF에 소요되는 막대한 비용(사람 레이블러 동원에 필요한 비용)과 사람의 주관적 편향성, 기술적 복잡성 등에 대한 한계를 보완하기 위하여 RLHF를 대체하는 방법론(예: Direct Preference Optimization, DPO)등이 꾸준히 연구 중으로, 향후 이러한 기술적 발전을 고려하여 안전장치를 확보하는 것이 바람직함



안전성 확보 조치 기준

미세조정 종류

- **파라미터 효율 미세조정(Parameter Efficient Fine-Tuning(PEFT))**
 - ^ 사전학습된 모델 파라미터(매개변수)를 동결하고 소수의 파라미터를 의도된 용도에 맞게 미세조정하는 것으로 학습 비용과 시간을 최소화하는 방법
- **지도학습 기반 미세조정(Supervised Fine-Tuning(SFT))**
 - ^ 비지도학습으로 만들어진 생성AI를 지도학습적으로 미세조정하는 과정으로, 바람직한 답변을 생성하도록 미리 정제되거나 레이블링된 데이터를 추가 학습
 - ^ ※ (예) 개인의 사생활을 묻는 프롬프트에 대하여 답변을 거부하는 내용의 답안을 학습시킴



안전성 확보 조치 기준

미세조정 종류

- 사람 피드백 기반 강화학습(Reinforcement Learning with Human Feedback(RLHF))
 - ^ 보상모델 생성(Reward Model Creation) : AI 모델이 생성한 출력물에 사람(라벨러)이 점수 또는 순위를 부여하고, 이를 토대로 보상모델을 훈련
 - ^ ※ (예) 개인의 사생활을 묻는 프롬프트에 대하여 사생활이 포함된 답변에는 (-1)의 보상을, 회피하는 답변에는 (+1)의 보상을 제공
 - ^ 정책 최적화(Policy Optimization): 보상모델을 사용하여 AI 모델의 정책을 최적화하는 단계로, 주로 정책 그라디언트 강화학습 알고리즘인 PPO(Proximal Policy Optimization)을 활용하여 미세조정



안전성 확보 조치 기준

미세조정을 통한 안전장치 추가

● 다양한 미세조정 방식 비교

다양한 미세조정 기법	파라미터 효율 미세조정 (PEFT)	지도학습 기반 미세조정 (SFT)	사람 피드백 기반 강화학습 (RLHF)
	Base LLM Tunable	Base LLM Tunable	SFT 등 LLM Tunable
	미세조정 답변생성	미세조정 답변생성	미세조정 답변생성
방법	소수의 파라미터 조정 (~0.01%)	이상적 답변 생성을 위한 추가학습	보상모델 생성 및 정책 최적화
학습데이터		X만개 ~ XX만개	X만개 ~ XX만개
학습 비용	X백개 이상	비교적 비쌈	비교적 비쌈
학습 시간	Minutes	Days	Days



Metric Evaluation

| 모델 성능 평가(Metric Evaluation)?

- 머신러닝과 데이터 분석에서 **모델 성능 평가(Metric Evaluation)**는 결과의 신뢰성과 품질을 판단하는 핵심 과정.
- 그중 Accuracy는 가장 기본적이고 직관적인 지표이며, 다양한 성능 지표와 함께 사용.

| 성능 측정 지표 (Performance Metrics)란?

- 성능 지표는 모델이 예측을 얼마나 잘 수행했는지를 수치적으로 표현한 값



Metric Evaluation

성능 측정 개요

- 객관적인 성능 측정의 중요성
 - ^ 모델 선택할 때 중요
 - ^ 현장 설치 여부 결정할 때 중요
- 일반화generalization 능력
 - ^ 학습에 사용하지 않았던 새로운 데이터에 대한 성능
 - ^ 가장 확실한 방법은 실제 현장에 설치하고 성능 측정 → 비용 때문에 실제 적용 어려움
 - ^ 주어진 데이터를 분할하여 사용하는 지혜 필요
 - ^ O/X의 문제가 아닌, 얼마나 일치하는가?



Metric Evaluation

성능 측정 개요

- 여러가지 평가 방법들
 - ^ Confusion Matrix 기반
 - ^ Accuracy
 - ^ Precision
 - ^ Recall
 - ^ F1 score
 - ^ AUC (Area Under the Curve) & ROC (Receiver Operating Characteristic)



Metric Evaluation

혼동 행렬과 성능 측정 기준

- 혼동 행렬(Confusion Matrix)

- △ 부류 별로 옳은 분류와 틀린 분류의 개수를 기록한 행렬
- △ 이진 분류에서 긍정positive과 부정negative
- △ 검출하고자 하는 것이 긍정(환자가 긍정이고 정상인이 부정, 불량품이 긍정이고 정상이 부정)
- △ 참 긍정(TP), 거짓 부정(FN), 거짓 긍정(FP), 참 부정(TN)의 네 경우

	실제 Positive	실제 Negative
예측 Positive	TP (True Positive)	FP (False Positive)
예측 Negative	FN (False Negative)	TN (True Negative)



Metric Evaluation

혼동 행렬과 성능 측정 기준

- 위의 혼동 행렬로부터 계산될 수 있는 주요 평가 지표(Metric)는 대표적으로 정확도 (accuracy), 오차 비율(error rate) = 1-정확도, 민감도(sensitivity 혹은 재현율 : Recall, Hit Ratio, TP Rate 등으로도 부름), 특이도(specificity), 거짓 긍정률(FP Rate), 정밀도 (precision) 등이 있으며, 이 중에서 정확도, 민감도, 정밀도 등은 특히 많이 사용되는 지표이다.
- 또한, 민감도와 정밀도를 조합한 F-Measure(혹은 F1-Score) 및 분석 모델의 예측값 과 실제값이 정확히 일치하는 정도를 계량화한 카파 통계(Kappa Statistic) 등이 정의되어 있다.



Metric Evaluation

주요 성능 지표 정리

지표	수식	설명
정확도 (Accuracy)	$(TP + TN) / (TP + TN + FP + FN)$	전체 샘플 중 정답 비율
정밀도 (Precision, PPV)	$TP / (TP + FP)$	Positive 예측 중 실제 Positive 비율
재현율 / 민감도 (Recall, Sensitivity, TPR)	$TP / (TP + FN)$	실제 Positive 중 맞춘 비율
특이도 (Specificity, TNR)	$TN / (TN + FP)$	실제 Negative 중 맞춘 비율
NPV (Negative Predictive Value)	$TN / (TN + FN)$	Negative 예측 중 실제 Negative 비율
F1-Score (F-Measure)	$2 \times (Precision \times Recall) / (Precision + Recall)$	정밀도와 재현율의 조화 평균
Fall-out (FPR, 위양성률)	$FP / (FP + TN)$	실제 Negative 중 잘못 Positive로 예측한 비율
Balanced Accuracy	$(TPR + TNR) / 2$	민감도와 특이도의 평균



Metric Evaluation

학습 데이터셋, 테스트 데이터셋

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

df_train = pd.read_csv("datasets/titanic_train.csv")
df_test = pd.read_csv("datasets/titanic_test.csv")
df_train.head(5)

from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer

# 특성과 타깃 분리
X_train = df_train.drop(columns=['survived'])
y_train = df_train['survived']
X_test = df_test.drop(columns=['survived'])
y_test = df_test['survived']

# 문자열 데이터를 원-핫 인코딩하기 위한 열 선택
categorical_features = X_train.select_dtypes(include=['object']).columns
numeric_features = X_train.select_dtypes(exclude=['object']).columns
```




Metric Evaluation

모델링

전처리 파이프라인 생성

```
preprocessor = ColumnTransformer(  
    transformers=[  
        ('num', Pipeline([  
            ('imputer', SimpleImputer(strategy='mean')),  
            ('scaler', StandardScaler())  
        ]), numeric_features),  
        ('cat', Pipeline([  
            ('imputer', SimpleImputer(strategy='constant', fill_value='missing')),  
            ('onehot', OneHotEncoder(handle_unknown='ignore'))  
        ]), categorical_features)  
    ])
```

Logistic Regression 분류 모델링

```
from sklearn.linear_model import LogisticRegression  
from sklearn.linear_model import LogisticRegression  
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, roc_curve, roc_auc_score  
import matplotlib.pyplot as plt
```

로지스틱 회귀 모델을 포함한 파이프라인 생성

```
lr = Pipeline(steps=[  
    ('preprocessor', preprocessor),  
    ('classifier', LogisticRegression(random_state=0))  
])
```



Metric Evaluation

모델 학습

```
# 모델 학습
lr.fit(X_train, y_train)

# 테스트 데이터셋에 대한 예측
y_pred = lr.predict(X_test)
y_pred_probability = lr.predict_proba(X_test)[:, 1]
```

분류 모델 평가


```
# 평가 지표 출력
print(f'Accuracy: {accuracy_score(y_test, y_pred)}')
print(f'Precision: {precision_score(y_test, y_pred)}')
print(f'Recall: {recall_score(y_test, y_pred)}')
print(f'F1 Score: {f1_score(y_test, y_pred)}')
print(f'ROC AUC Score: {roc_auc_score(y_test, y_pred_probability)}')
```



Metric Evaluation

ROC Curve 그리기

```
fpr, tpr, thresholds = roc_curve(y_test, y_pred_probability)
plt.plot(fpr, tpr, label='Logistic Regression')
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('ROC Curve')
plt.legend()
plt.show()
```





Metric Evaluation

분류 모델 평가

```
from sklearn.metrics import confusion_matrix
```

```
# Confusion Matrix를 출력합니다.
```

```
confmat = confusion_matrix(y_true=y_test, y_pred=y_pred)  
print(confmat)
```

```
[[92 13]  
 [19 55]]
```

Accuracy: 0.8212 = $(92+55) / (92+13+19+55)$

Precision: 0.8088

Recall: 0.7432

F1 Score: 0.7746

ROC AUC Score: 0.8961

실제값(Reference)

	실제값(Reference)	
	Y	N
예측값(Prediction)		
Y	True Positive(TP)	False Positive(FP)
N	False Negative(FN)	True Negative(TN)

Accuracy

$$\frac{TP + TN}{TP + FP + FN + TN}$$

전체 예측에서(예측이 Y이든 N이든 무관하게) 옳은 예측의 비율



모델 성능 평가 예

실습 모듈 불러오기

Scikit Learn 제공 Toy Data를 사용한 실습 모듈 불러오기

데이터 셋과 의사결정 트리 기반 분류기 관련 클래스 불러오기

```
from sklearn import datasets  
from sklearn.tree import DecisionTreeClassifier
```

테스트를 위해 사용하는 데이터 셋의 분리 방법 관련 모듈 불러오기

```
from sklearn.model_selection import train_test_split  
from sklearn.model_selection import StratifiedKFold  
from sklearn.model_selection import cross_val_score
```

성능 평가 관련 모듈 불러오기

```
from sklearn.metrics import confusion_matrix  
from sklearn.metrics import accuracy_score  
from sklearn.metrics import classification_report  
from sklearn.metrics import roc_auc_score  
from sklearn.metrics import mean_squared_error
```



모델 성능 평가 예

| 데이터 셋 구성

데이터 셋 준비

```
data = datasets.load_breast_cancer()  
X = data.data  
y = data.target
```

홀드 아웃

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2)
```



모델 성능 평가 예

결정 트리 분류 모델 생성

```
clf = DecisionTreeClassifier()
```

```
clf.fit(X_train, y_train)
```

```
clf
```

```
-----
```

```
clf = DecisionTreeClassifier()  
clf.fit(X_train, y_train)  
clf
```

```
▼ DecisionTreeClassifier ⓘ ⓘ  
DecisionTreeClassifier()
```

테스트 데이터에 대한 예측 값

```
y_pred = clf.predict(X_test)
```



모델 성능 평가 예

모델 성능 평가

```
print("Confusion Matrix")
print(confusion_matrix(y_test, y_pred))
-----
Confusion Matrix
[[43  1]
 [ 3 67]]

print("Accuracy")
print(accuracy_score(y_test, y_pred, normalize = True))
----
Accuracy
0.9649122807017544
```




모델 성능 평가 예

모델 성능 평가

```
print("Classification Report")
print(classification_report(y_test, y_pred))
```

Classification Report

	precision	recall	f1-score	support
0	0.93	0.98	0.96	44
1	0.99	0.96	0.97	70
avg / total	0.97	0.96	0.97	114

```
print("AUC")
print(roc_auc_score(y_test, y_pred))
```

AUC 0.9672077922077924

```
print("Mean Squared Error")
print(mean_squared_error(y_test, y_pred))
```

Mean Squared Error

0.03508771929824561



모델 성능 평가 예

K 홀드 아웃 검증을 통한 실습

```
skf = StratifiedKFold(n_splits=10)
skf.get_n_splits(X, y)
print(skf)
```

```
for train_index, test_index in skf.split(X, y):
    print("Train set :", train_index)
    print("Test set:", test_index)
```

```
Train set : [ 25  26  27  28  29  30  31  32  33  34  35  36  38  39  40  41  42  43
  44  45  47  53  54  56  57  62  64  65  70  72  73  75  77  78  82  83
  85  86  87  91  94  95  99 100 102 103 104 105 106 107 108 109 110 111
 112 113 114 115 116 117 118 119 120 121 122 123 124 125 126 127 128 129
 130 131 132 133 134 135 136 137 138 139 140 141 142 143 144 145 146 147
 148 149 150 151 152 153 154 155 156 157 158 159 160 161 162 163 164 165.
```

....



모델 성능 평가 예

K 홀드 아웃 검증을 통한 실습

성능 평가

```
clf = DecisionTreeClassifier()
scores = cross_val_score(clf, X, y, cv=skf)
print("K Fold Cross Validation Score")
print(scores)
print("Average Accuracy")
print(scores.mean())
-----
K Fold Cross Validation Score
[0.89655172 0.87931034 0.92982456 0.87719298 0.92982456 0.89473684
 0.87719298 0.94642857 0.92857143 0.96428571]
Average Accuracy
0.9123919713075791
```



모델 성능 평가 예

K 홀드 아웃 검증을 통한 실습

데이터 셋 구성 shuffle

```
skf_sh = StratifiedKFold(n_splits=10, shuffle=True)
skf_sh.get_n_splits(X, y)
print(skf_sh)
-----
```

```
for train_index, test_index in skf_sh.split(X, y):
    print("Train set:", train_index)
    print("Test set:", test_index)
```

```
-----
Train set: [ 0  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17
 18 19 20 21 22 25 26 27 29 30 31 32 33 34 35 36 37 38
 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57
 59 60 61 62 63 64 65 66 67 68 69 70 71 72 73 75 76 78
 80 81 82 83 85 86 87 88 89 90 92 93 95 96 99 100 101 102
103 104 105 106 107 108 109 110 111 112 113 114 115 116 117 118 119 120
.....
```



모델 성능 평가 예

K 홀드 아웃 검증을 통한 실습

```
clf = DecisionTreeClassifier()
scores = cross_val_score(clf, X, y, cv=skf_sh)
print("K Fold Cross Validation Score")
print(scores)
print("Average Accuracy")
print(scores.mean())
-----
K Fold Cross Validation Score
[0.93103448 0.96551724 0.87719298 0.9122807  0.96491228 0.94736842
 0.9122807  0.92857143 0.92857143 0.91071429]
Average Accuracy
0.9278443954714373
```

평균 Accurac가 0.93으로 약간 상승한 것을 확인할 수 있습니다.



Session 8

Self 점검 · 종합 실습

3일차 오후 | 3.5시간



종합 실습 — Titanic 전처리 파이프라인

```
import pandas as pd, numpy as np
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.linear_model import LogisticRegression
from sklearn.pipeline import make_pipeline
from sklearn.model_selection import StratifiedKFold, cross_val_score

df = pd.read_csv('datasets/titanic.csv')

# ① 결측값 처리
df['Age'].fillna(df['Age'].mean(), inplace=True)
df.drop('Cabin', axis=1, inplace=True)
df['Embarked'].fillna(df['Embarked'].mode()[0], inplace=True)

# ② 이상치 제거 (Fare 3σ)
df = df[abs(df['Fare']-df['Fare'].mean()) <= 3*df['Fare'].std()]

# ③ 인코딩
le = LabelEncoder()
df['Gender_enc'] = le.fit_transform(df['Gender'])
df = pd.get_dummies(df, columns=['Embarked'], prefix='Emb')

# ④ 특성 선택 및 Pipeline + Stratified K-Fold
X = df[['Pclass', 'Age', 'SibSp', 'Parch', 'Fare', 'Gender_enc', 'Emb_C', 'Emb_Q', 'Emb_S']]
y = df['Survived']
pipeline = make_pipeline(StandardScaler(), LogisticRegression(random_state=42))
skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
cv = cross_val_score(pipeline, X, y, cv=skf, scoring='accuracy', n_jobs=-1)
print(f'평균 정확도: {cv.mean():.4f} ± {cv.std():.4f}')
```



3과목 Self 점검 — 핵심 개념 체크리스트

- Data Pre-processing 정의: Cleansing / Reduction / Wrangling 포함
- 데이터 품질 9요소: 잡음·아티팩트·바이어스·이상치·결측치·불일치·중복·정밀도·정확도
- 데이터 유형 3종: 정형/반정형/비정형 — 특징, 저장방식, 수집 난이도
- Pandas Series vs DataFrame: 1D vs 2D, 생성/인덱싱/집계 방법
- Data Gathering 6가지 방법: 파일/DB/API/웹스크래핑/스트리밍/센서
- 3σ 법칙: 평균 $\pm 3\sigma$ 밖 = 전체 0.27% → 이상치 제거 기준
- 결측값 3유형: MCAR / MAR / MNAR — 각 처리 방법 차이
- fillna vs dropna: 값 채우기 vs 행/열 삭제
- Data Cleansing 절차: Matching → Formatting → Filtering & Sorting
- merge how 4가지: inner / left / right / outer 차이
- Data Reduction 기법: Feature Selection / PCA / Sampling / Dedup
- Min-Max vs Z-score 선택: 이상치 없으면 Min-Max, 있으면 Z-score
- Label vs One-Hot Encoding: 정수화(순서범주) vs 이진벡터화
- K-Fold 원리: K등분 → 1개씩 테스트 → K번 반복 → 평균 성능
- Pipeline 역할: 전처리+모델 연결, Data Leakage 방지



수고하셨습니다!

Python 데이터 전처리 3과목 완료

Data Preprocessing · EDA · Cleansing · Integration
Reduction · Transformation · Encoding · Cross Validation

Prepared by DaeKyeong Kim, Ph.D. | Samsung Display Interface